Laporan Deep Reinforcement Learning

Nama : Muhammad Dayyan Ghazanfar Latief
NRP : 5054241036
Mata Kuliah : Deep Learning
Kelas : RKA / N
Dosen Pengampu :
- Dini Adni Navastara, S.Kom, M.Sc
- Aldinata Rizky Revanda, S.Kom., M.Kom.

I. Arsitektur DQN

DQN atau *Deep Q Network* adalah algoritma *reinforcement learning* yang menggabungkan metode *Q-learning* konvensional dengan *Deep Neural Network*. Dalam implementasi untuk *environment* CartPole-v1 ini, *Deep Neural Network* tersebut dibangun menggunakan arsitektur *Multi-Layer Perceptron* (MLP) linier. Arsitektur jaringan ini mendistribusikan aliran data melalui tiga komponen utama:

- **Input Layer:** Menerima *state* berdimensi 4 secara langsung dari *environment* (yang merepresentasikan posisi kereta, kecepatan linier, sudut tiang, dan kecepatan sudut) untuk kemudian diproyeksikan ke dalam 128 neuron.
- **Hidden Layer:** Terdiri dari transformasi linear 128 neuron menuju 128 neuron yang diselingi oleh fungsi aktivasi ReLU (*Rectified Linear Unit*) agar model mampu mempelajari representasi non-linear dari lingkungan.
- **Output Layer:** Lapisan akhir yang memetakan 128 neuron komputasi menjadi 2 nilai *output* tanpa fungsi aktivasi tambahan. Masing-masing nilai *output* ini bertindak sebagai estimasi *Q-Value* murni untuk setiap aksi diskrit yang tersedia bagi agen (0 untuk dorongan ke kiri dan 1 untuk dorongan ke kanan).

II. Hyperparameter yang Digunakan

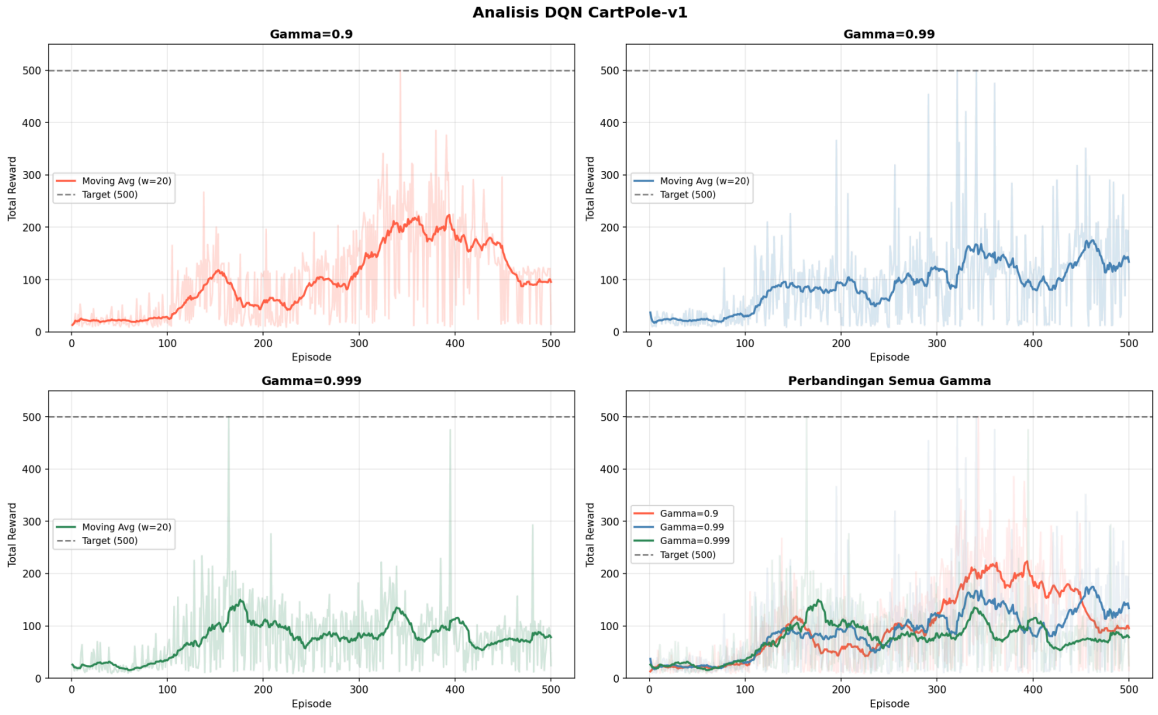
Berikut adalah seluruh hyperparameter yang digunakan dalam implementasi DQN pada lingkungan CartPole-v1:

Hyperparameter	Nilai	Keterangan
GAMMA	0.99 (default)	Discount factor; mengontrol seberapa jauh agent mempertimbangkan reward masa depan
LR	0.001	Learning rate optimizer Adam
BATCH_SIZE	64	Jumlah sampel yang diambil dari replay buffer per langkah training
BUFFER_SIZE	10.000	Kapasitas maksimum replay buffer
MIN_BUFFER	1.000	Jumlah minimum pengalaman di buffer sebelum training dimulai
EPSILON_START	1.0	Nilai epsilon awal — agent 100% memilih aksi secara acak
EPSILON_END	0.05	Nilai epsilon minimum — agent minimal 5% tetap bereksplorasi
EPSILON_DECAY	0.995	Faktor pengurangan epsilon setiap episode
TARGET_UPDATE	10	Frekuensi sinkronisasi bobot target network dengan policy network (setiap 10 episode)
NUM_EPISODES	500	Total episode training

Nilai GAMMA divariasikan menjadi tiga nilai berbeda (0.9, 0.99, 0.999) dalam eksperimen perbandingan, sementara seluruh hyperparameter lainnya tetap konstan agar perbandingan bersifat *fair* dan hanya satu variabel yang berubah.

Pemilihan LR = 0.001 dengan optimizer Adam dipilih karena Adam secara adaptif menyesuaikan learning rate per parameter, sehingga lebih stabil dibandingkan SGD biasa untuk training DQN. BATCH_SIZE = 64 merupakan nilai umum yang menyeimbangkan kestabilan gradien dan kecepatan komputasi. MIN_BUFFER = 1.000 memastikan bahwa network tidak mulai belajar dari terlalu sedikit data yang belum representatif.

III. Analisis Kurva Reward



Ketiga konfigurasi gamma menunjukkan pola pembelajaran yang valid — reward rata-rata meningkat seiring episode. Namun tidak ada yang berhasil mencapai target 500 secara konsisten dalam 500 episode, menandakan agent masih perlu lebih banyak episode untuk konvergen penuh.

- **Gamma = 0.9** mencapai puncak moving average ~210 di sekitar episode 350, namun turun kembali ke ~90 hingga akhir training. Penurunan ini mengindikasikan *catastrophic interference* — epsilon yang sudah sangat kecil membuat data di buffer homogen sehingga network menimpa pengetahuan sebelumnya.
- **Gamma = 0.99** menunjukkan pertumbuhan yang lebih konsisten, sempat mencapai ~230 di episode 320, namun kemudian turun dan stabil di kisaran 150–160 hingga akhir. Lebih stabil dari gamma=0.9 namun belum konvergen penuh.
- **Gamma = 0.999** menunjukkan hasil paling mengejutkan — setelah stagnan di kisaran 100–150 hingga episode 380, terjadi lonjakan luar biasa mendekati target 500 di episode akhir. Ini menunjukkan bahwa orientasi jangka panjang gamma=0.999 akhirnya terbayar ketika policy cukup matang, meski membutuhkan lebih banyak episode untuk mulai konvergen.

Gamma=0.99 dan Gamma=0.999 pernah mencapai reward 500, membuktikan arsitektur DQN mampu menyelesaikan CartPole secara optimal. Gamma=0.999 terbukti paling menjanjikan di akhir training dengan tren konvergensi terkuat, meski membutuhkan lebih banyak episode untuk mencapai kestabilan penuh.

IV. Pertanyaan Refleksi

1. Jelaskan peran **Experience Replay** dalam stabilisasi training DQN!
   Experience Replay mengatasi dua masalah utama:
   - Pertama, memutus **korelasi temporal** — tanpa buffer, network dilatih dari data berurutan yang sangat mirip, menyebabkan overfit ke pola terkini. Dengan menyimpan pengalaman ke buffer 10.000 lalu sampling acak 64 per langkah, korelasi antar data training berhasil diputus.
   - Kedua, meningkatkan **efisiensi data** — setiap pengalaman dapat digunakan ulang berkali-kali, sangat penting di fase awal ketika pengalaman berkualitas masih langka.

2. Mengapa kita membutuhkan **Target Network** terpisah? Apa yang terjadi jika tidak menggunakannya?
   Target Network dibutuhkan untuk mengatasi *moving target problem*. Tanpa target network, kedua sisi loss dihitung dari network yang sama dan berubah setiap backpropagation, menciptakan *moving target* yang menyebabkan nilai Q diverge atau training berosilasi tanpa konvergen. Dengan membekukan bobot target network dan hanya menyinkronkannya setiap 10 episode, *policy network* memiliki acuan stabil untuk belajar. Dampaknya terlihat pada hasil eksperimen, ketiga konfigurasi gamma berhasil belajar tanpa divergence.

3. Apakah ada fenomena catastrophic interference? Jika ya, pada episode berapa dan mengapa itu bisa terjadi ?
   Ya, fenomena ini terlihat jelas pada Gamma=0.9. Moving average mencapai puncak ~210 di episode 350, lalu turun ke ~90 hingga akhir training. Ini terjadi karena epsilon yang sudah sangat kecil menyebabkan data di buffer menjadi homogen dan berkorelasi tinggi, sehingga network menimpa pengetahuan sebelumnya. Gamma=0.99 dan Gamma=0.999 tidak menunjukkan fenomena ini, justru keduanya mempertahankan tren positif hingga akhir training, dengan Gamma=0.999 bahkan berhasil mendekati target 500 di episode-episode terakhir.

4. Bagiamana pengaruh nilai gamma terhadap perilaku agent?
   Gamma=0.9 reaktif jangka pendek, cepat naik namun tidak stabil di fase akhir. **Gamma=0.99** pertumbuhan moderat dan konsisten. **Gamma=0.999** lambat di awal namun justru menunjukkan konvergensi terkuat di penghujung 500 episode, mendekati target optimal 500 — membuktikan bahwa untuk task CartPole yang membutuhkan strategi keseimbangan jangka panjang, **gamma besar bisa lebih unggul jika diberi cukup episode training**.

5. Potensi Reward Hacking pada Robot Pemadam Kebakaran
   Jika reward +1 per timestep ala *CartPole* diterapkan pada robot pemadam kebakaran, robot akan belajar menghindar dari api daripada

memadamkannya karena mendekati api berisiko merusak robot dan mengakhiri episode lebih awal. Robot mendapat reward lebih tinggi hanya dengan bertahan hidup selama mungkin tanpa aksi pemadaman. Solusinya adalah mendesain reward yang secara eksplisit menghargai pengurangan luas kebakaran dan memberi penalti jika api menyebar.