Dokumen Teknis: Physics-Informed Underwater Image Enhancement dengan NAFNet Backbone dan Perceptual Loss DINOv2

Judul Proyek: Physics-Informed Underwater Image Enhancement dengan NAFNet Backbone dan Perceptual Loss DINOv2

Status: Dokumen Kerja Tim — Draft untuk Pengembangan Laporan

1. Latar Belakang

1.1 Urgensi dan Konteks Aplikasi

Pencitraan bawah air (underwater imaging) merupakan komponen kritis dalam berbagai domain strategis dan ilmiah. Di sektor kelautan, perdagangan laut global mencapai $2.2 triliun pada 2023, dengan pariwisata pesisir dan maritim menyumbang $725 miliar (UNCTAD, 2025). Aktivitas eksplorasi sumber daya laut — inspeksi pipa bawah laut, arkeologi bawah air, pemetaan terumbu karang, dan survei geologi dasar laut — sangat bergantung pada kualitas visual yang dihasilkan kamera bawah air. Di bidang robotika, Autonomous Underwater Vehicles (AUV) dan Remotely Operated Vehicles (ROV) semakin banyak digunakan untuk misi di lingkungan berbahaya atau tidak dapat dijangkau manusia (Singh et al., 2023). Sistem persepsi visual pada AUV — yang mencakup deteksi objek, SLAM, dan navigasi — secara langsung bergantung pada kualitas frame yang ditangkap kamera.

Permasalahan mendasar adalah bahwa kamera konvensional tidak dirancang untuk medium air. Medium air menginduksi degradasi unik dan parah pada citra yang ditangkap, sehingga secara substansial menurunkan performa sistem computer vision downstream.

1.2 Fisika Degradasi Citra Bawah Air

Degradasi citra bawah air bersumber dari dua fenomena fisika fundamental: **absorpsi cahaya** dan **hamburan cahaya (scattering)**.

Absorpsi cahaya di dalam air bersifat sangat selektif terhadap panjang gelombang (wavelength-dependent). Cahaya merah (620-750 nm) diserap paling cepat — habis dalam kedalaman beberapa meter pertama. Cahaya hijau (495-570 nm) terserap lebih lambat, dan cahaya biru (380-495 nm) memiliki penetrasi terdalam (Xu et al., 2023). Konsekuensinya adalah hampir seluruh citra bawah air memiliki dominasi warna biru-hijau yang kuat (color cast) dan defisit parah pada channel merah.

Hamburan cahaya terjadi ketika foton berinteraksi dengan partikel tersuspensi dalam air (sedimen, plankton, partikel organik). Hamburan maju (forward scattering) menyebabkan

blurring detail halus, sedangkan hamburan balik (backscattering) membentuk lapisan kabut (haze) yang menurunkan kontras secara global (Xu et al., 2023)(Guo et al., 2024).

Fenomena ini dimodelkan secara matematis melalui model Jaffe-McGlamery yang dikembangkan Jaffe (1990) di IEEE Journal of Oceanic Engineering. Versi yang disederhanakan dinyatakan sebagai:

```
I(x) = J(x) * t(x) + A * (1 - t(x))
```

di mana I(x) adalah citra yang diamati, J(x) adalah citra bersih laten, t(x) adalah peta transmisi, dan A adalah cahaya latar (ambient light). Per-channel transmittance mengikuti Beer-Lambert law:

```
t_c(x) = exp(-beta_c * d(x))
```

di mana beta_c adalah koefisien atenuasi untuk channel c ∈ {R, G, B} dan d(x) adalah kedalaman piksel (Jaffe, 1990).

Dampak kumulatif kedua fenomena ini adalah citra bawah air yang khas ditandai oleh: color cast biru/hijau; kontras rendah akibat backscattering; hilangnya detail tekstur; serta ketidakmerataan iluminasi akibat refraksi dan distribusi sumber cahaya.

1.3 Perkembangan Metode UIE dan Kesenjangannya

Underwater Image Enhancement (UIE) telah melalui evolusi panjang dari metode konvensional berbasis model fisika menuju metode berbasis deep learning (Guo et al., 2024)(Paull et al., 2025).

1.3.1 Metode Konvensional: Keterbatasan Adaptabilitas

Metode berbasis model fisika awal seperti UDCP (Drews et al., 2013) mengadaptasi Dark Channel Prior dari He et al. (He et al., 2011) untuk underwater. Metode ini mencapai PSNR hanya ~16.22 dB di UIEB, seringkali over-dehaze, dan tidak adaptif terhadap variasi kondisi air. Histogram equalization dan color balance tradisional memberikan peningkatan kontras namun tidak menangani physical color cast secara fundamental.

1.3.2 Metode Deep Learning: GAN dan Instabilitas Training

Metode berbasis GAN seperti FUnIE-GAN (Islam et al., 2020) adalah terobosan pertama yang memungkinkan UIE real-time dengan 7.02M parameter. Namun, GAN training dikenal tidak stabil: mode collapse, vanishing gradient pada discriminator, dan sensitivitas tinggi terhadap hyperparameter. Survei komprehensif UIE berbasis GAN (Tandfonline, 2025) mengkonfirmasi bahwa metode GAN menghadapi generalization issues dan high computational demands yang membatasi penerapan praktisnya (Paull et al., 2025).

1.3.3 Metode CNN Berbasis Fisika: HuWIE-Net

HuWIE-Net (Eksioglu et al., 2025) adalah metode modern yang menggabungkan CNN dengan physics-informed module. Namun, HuWIE-Net menggunakan koefisien atenuasi beta global (bukan per-channel), padahal Beer-Lambert law secara eksplisit menyatakan diferensial atenuasi per panjang gelombang. Kapasitas model yang sangat ringan (0.56M parameter) juga membatasi kemampuannya menangani long-range spatial dependency.

1.3.4 Metode Transformer: Performa Tinggi, Beban Komputasi Ekstrem

U-shape Transformer (Peng et al., 2023) mencapai PSNR 24.16 dB di LSUI Test-L400 dan 22.91 dB di UIEB, menjadi SOTA di benchmark utama. Namun, model ini memiliki 65.6M parameter, membutuhkan 800 epoch training dari scratch, dan sangat tidak cocok untuk deployment di edge device atau AUV.

Percobaan langsung tim dalam penelitian ini menggunakan Restormer (Zamir et al., 2022) sebagai backbone (36.5M parameter) dengan fine-tuning transfer learning 35 epoch di LSUI menghasilkan PSNR ~17 dB dengan koreksi warna hampir tidak terjadi. Hal ini mengonfirmasi temuan dalam literature: domain gap antara natural image restoration dan underwater image enhancement sangat besar, dan fine-tuning dengan epoch terbatas tidak cukup tanpa strategi yang tepat (Jiang et al., 2022)(Wang et al., 2023).

1.4 Kesenjangan Penelitian yang Ada

Survey komprehensif UIE terkini (Guo et al., 2024) mengidentifikasi beberapa kesenjangan utama:

1. **Kesenjangan antara model fisika dan deep learning**: Metode berbasis fisika murni tidak memiliki kemampuan generalisasi yang baik untuk variasi kondisi air berbeda, sementara metode data-driven murni mengabaikan constraint fisika yang dapat meningkatkan plausibilitas output.
2. **Permasalahan color correction yang fundamental**: Metode yang menggunakan beta global dalam physics branch tidak dapat secara akurat memodelkan differential attenuation per channel, yang merupakan penyebab utama color cast bawah air.
3. **Keterbatasan metrik perceptual yang ada**: VGG-based perceptual loss yang umum digunakan dalam restoration dilatih pada natural images (ImageNet) dan tidak optimal untuk domain underwater yang memiliki distribusi warna fundamentally berbeda.
4. **Tradeoff performa vs. efisiensi komputasi**: Model terbaik (U-shape Transformer, 65.6M parameter) sangat berat untuk deployment praktis, sedangkan model ringan masih jauh dari performa SOTA.
5. **Kurangnya strategi transfer learning yang tepat**: Sebagian besar metode SOTA dilatih dari scratch, mengabaikan potensi pretrained general restoration backbone untuk mempercepat konvergensi dan mengurangi kebutuhan data.

Penelitian ini dirancang untuk menjawab kesenjangan-kesenjangan tersebut melalui framework terpadu yang menggabungkan backbone general restoration yang efisien (NAFNet),

physics-informed branch dengan koefisien per-channel (PINN), dan perceptual loss berbasis representasi visual yang robust dan domain-agnostic (DINOv2).

2. Rumusan Masalah

Berdasarkan uraian latar belakang di atas, terdapat lima rumusan masalah yang menjadi fokus penelitian ini:

RM-1: Bagaimana merancang arsitektur deep learning untuk UIE yang dapat secara simultan menangani koreksi warna, haze removal, dan pemulihan detail, dengan memanfaatkan pretrained general restoration backbone (NAFNet) melalui strategi transfer learning yang tepat, sehingga dapat mencapai konvergensi dalam 50-60 epoch pada resource GPU terbatas (single A100 40GB)?

RM-2: Bagaimana mengintegrasikan physics-informed neural network (PINN) berbasis model Beer-Lambert dengan koefisien atenuasi per channel (beta_R, beta_G, beta_B) ke dalam pipeline deep learning, dan sejauh mana constraint fisika ini meningkatkan kualitas koreksi warna dibanding pendekatan end-to-end tanpa constraint fisika?

RM-3: Apakah penggunaan DINOv2 sebagai perceptual loss — menggantikan VGG yang dilatih pada natural images — memberikan peningkatan kualitas perseptual pada output UIE yang secara distribusi berbeda dari natural images, dan berapa besaran pengaruhnya terhadap metrik PSNR, SSIM, dan UCIQE?

RM-4: Seberapa besar kontribusi individual dari masing-masing komponen framework (backbone NAFNet, PINN branch, DINOv2 perceptual loss) terhadap peningkatan kualitas output, yang diukur melalui ablation study sistematis pada benchmark LSUI Test-L400 dan UIEB-890?

RM-5: Apakah framework yang diusulkan dapat mencapai atau melampaui performa U-shape Transformer sebagai metode SOTA UIE di LSUI (PSNR > 24.16 dB, SSIM > 0.906) dan UIEB (PSNR > 22.91 dB, SSIM > 0.820), dengan jumlah parameter yang lebih sedikit (<20M vs. 65.6M) dan waktu training yang lebih singkat?

3. Related Works

3.1 Model Fisika Underwater: Jaffe-McGlamery dan Beer-Lambert

Landasan fisika pemodelan degradasi underwater berasal dari model yang dikembangkan Jaffe (1990) di IEEE Journal of Oceanic Engineering (Jaffe, 1990). Model ini menyatakan bahwa irradiance total yang diterima kamera underwater merupakan superposisi direct component, forward scatter, dan backscatter. Versi disederhanakan yang dipakai secara luas dalam UIE modern adalah:

```
I(x) = J(x) * t(x) + A * (1 - t(x))
t_c(x) = exp(-beta_c * d(x))
```

Model ini telah divalidasi secara luas dan dipakai sebagai basis dari metode klasik UDCP hingga metode DL modern seperti HuWIE-Net (Eksioglu et al., 2025), UIE-UnFold, dan WaterFormer. Survey komprehensif oleh Guo et al. (Guo et al., 2024) (Signal Processing: Image Communication, Elsevier, 2024) mengonfirmasi bahwa model ini menjadi fondasi terbanyak dipakai dalam DL-based UIE.

Justifikasi: Model Beer-Lambert adalah satu-satunya model fisika underwater yang secara matematis terdokumentasi baik dan memiliki parameter yang dapat diestimasi oleh neural network (beta_c dan d). Menggunakan model ini memungkinkan physics consistency loss yang bermakna secara fisika, bukan sekadar regularizer empiris.

3.2 Physics-Guided Deep Learning untuk Image Restoration

Paradigma physics-guided deep learning — di mana constraint fisika diintegrasikan ke dalam loss function atau arsitektur neural network — telah terbukti meningkatkan performa dan robustness pada berbagai task image restoration.

Pan et al. (2021) (IEEE TPAMI, 2021) — "Physics-Based Generative Adversarial Models for Image Restoration and Beyond" — menunjukkan bahwa memaksa output model konsisten dengan physics model melalui physics consistency loss menghasilkan performa yang lebih baik dibanding GAN murni tanpa constraint fisika. Ini adalah justifikasi langsung untuk physics consistency loss yang digunakan dalam penelitian ini.

Studi terkini di domain underwater juga mengkonfirmasi hal ini: BLUE-Net (Li et al., 2025) (Engineering Applications of Artificial Intelligence, Elsevier, 2025) mengusulkan pendekatan deep unrolling berbasis physics-driven prior learning untuk UIE dan menunjukkan peningkatan signifikan dibanding metode tanpa physics constraint. UPMC-Net (Zhang et al., 2025) (Digital Signal Processing, Elsevier, 2025) menggunakan Physical Model Constraint network yang terbukti meningkatkan natural color restoration di benchmark UIEB.

3.3 Deep Learning untuk UIE: Evolusi Arsitektur

3.3.1 Survei dan Benchmark Terkini

Survey komprehensif UIE berbasis deep learning yang dipublikasikan di dua jurnal peer-reviewed utama menjadi landasan konteks penelitian ini:

- Guo et al. (Guo et al., 2024) (Signal Processing: Image Communication, Elsevier, 2024) — review 120+ metode UIE mencakup teknik, dataset, kode, dan evaluasi metrik.
- Xu et al. (Xu et al., 2023) (Neurocomputing, Elsevier, 2023) — review metode berbasis GAN untuk UIE dengan analisis komparatif performa.

Tabel PSNR/SSIM metode utama di UIEB dan LSUI:

Metode	Venue	PSNR UIEB (dB)	SSIM UIEB	PSNR LSUI-L400 (dB)
UDCP	TIP 2011	16.22	0.69	—
FUnIE-GAN	IEEE RA-L 2020	21.20	0.80	~21.0

Metode	Venue	PSNR UIEB (dB)	SSIM UIEB	PSNR LSUI-L400 (dB)
U-shape Transformer	IEEE TIP 2023	22.91	0.906	24.16
HuWIE-Net	IEEE Access 2025	Competitive	—	—

3.3.2 GAN-based Methods

FUnIE-GAN (Islam et al., IEEE RA-L 2020) (Islam et al., 2020) adalah metode GAN pioner untuk UIE real-time dengan 7.02M parameter. Meskipun cepat, GAN training tidak stabil dan kualitasnya terbatas. Survey UIE berbasis GAN (International Journal of Communication Systems, Tandfonline, 2025) (Paull et al., 2025) mengkonfirmasi bahwa metode GAN menghadapi generalization issues, high computational demands, dan dataset biases.

3.3.3 CNN-based Physics-Guided: HuWIE-Net

HuWIE-Net (Eksioglu et al., 2025) (IEEE Access, 2025) menggabungkan CNN dengan physics-informed module. Keterbatasannya: beta global (bukan per-channel), kapasitas sangat terbatas (0.56M parameter), dan tidak ada perceptual loss — sehingga output cenderung over-smoothed.

3.3.4 Transformer-based: U-shape Transformer

U-shape Transformer (Peng et al., 2023) mencapai PSNR 24.16 dB di LSUI Test-L400 dan 22.91 dB di UIEB sebagai SOTA. Kelemahannya: 65.6M parameter, 800 epoch training dari scratch, tidak feasible untuk resource terbatas.

3.3.5 Transfer Learning dan Domain Adaptation untuk UIE

Jiang et al. (2022) (Pattern Recognition, Elsevier, 2022) — "Two-step domain adaptation for underwater image enhancement" — menunjukkan bahwa transfer dari domain dehazing di atas air ke UIE menggunakan domain adaptation mengatasi keterbatasan data underwater berpasangan. DOI: 10.1016/j.patcog.2021.108324.

Wang et al. (Wang et al. (2023) — "Domain Adaptation for Underwater Image Enhancement" (TUDA) — memvalidasi bahwa domain gap (inter-domain: synthetic vs. real; intra-domain: variasi kondisi air) adalah masalah nyata dalam UIE yang perlu ditangani secara eksplisit. DOI: 10.1109/TIP.2023.3244647.

Relevansi untuk proyek ini: Kita menggunakan pretrained NAFNet (dilatih di SIDD — denoising natural images) dan fine-tune ke UIE di LSUI. Ini adalah transfer learning cross-domain yang didukung oleh kedua paper di atas. Strategi soft-freeze warmup konsisten dengan rekomendasi dari studi ini.

3.4 NAFNet sebagai General Image Restoration Backbone

Chen et al. (2022) (ECCV 2022) — "Simple Baselines for Image Restoration" — memperkenalkan NAFNet (Nonlinear Activation Free Network) yang mencapai SOTA pada GoPro deblurring (33.69 dB) dan SIDD denoising (40.30 dB) dengan hanya 8.4% FLOPs dari metode sebelumnya.

Kunci arsitektur NAFNet adalah penghilangan nonlinear activation function dan menggantinya dengan SimpleGate (perkalian dua half-channel). Studi komparatif terbaru (Chen et al., 2025) mengkonfirmasi bahwa SimpleGate dan Simplified Channel Attention merupakan komponen krusial — menghilangkan salah satunya menurunkan PSNR secara konsisten.

NAFNet juga telah digunakan dalam konteks UIE: "Underwater Image Enhancement Based on the Fusion of PUIENet and NAFNet" (ECCV 2022 Workshop) menunjukkan kompatibilitasnya dengan domain underwater.

Mengapa NAFNet dan bukan Restormer: Percobaan langsung tim dengan Restormer (Zamir et al., 2022) (36.5M parameter) selama 35 epoch di LSUI hanya menghasilkan PSNR ~17 dB. NAFNet secara arsitektural lebih ringan (~17-20M parameter), lebih mudah di-fine-tune, dan terbukti sebagai general restoration backbone yang fleksibel.

3.5 Perceptual Loss: Dari VGG ke DINOv2

Konsep perceptual loss diperkenalkan oleh Johnson et al. (Johnson et al., 2016) (ECCV 2016) — "Perceptual Losses for Real-Time Style Transfer and Super-Resolution" — menggunakan features dari VGG-16 pretrained di ImageNet. Pendekatan ini diadopsi luas di image restoration.

Keterbatasan VGG untuk UIE: VGG dilatih untuk klasifikasi natural images (ImageNet). Features VGG bias ke distribusi warna dan statistik natural images, sehingga tidak optimal sebagai perceptual metric untuk underwater images yang memiliki distribusi berbeda secara fundamental.

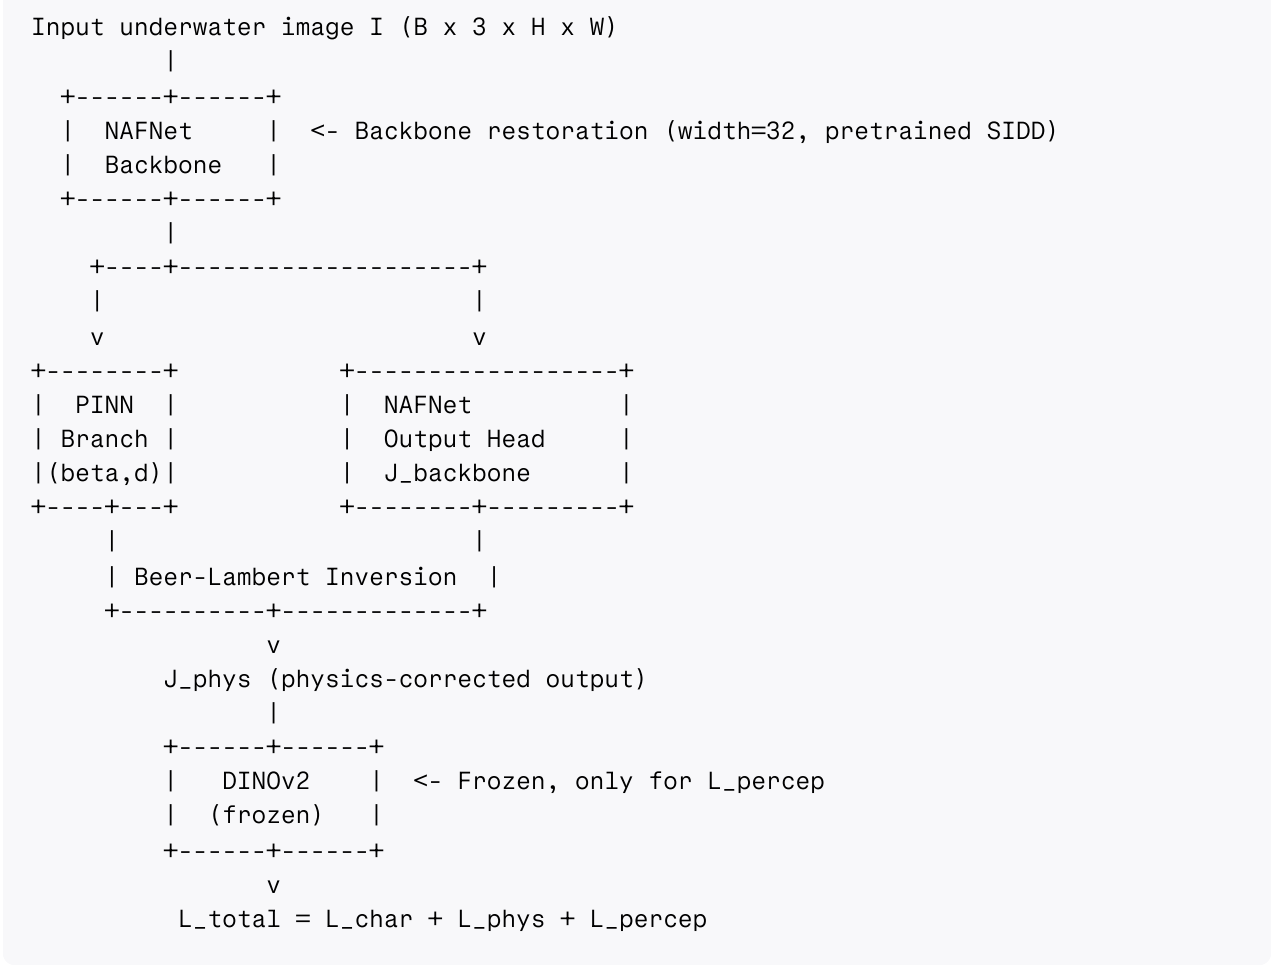
DINOv2 (Oquab et al., 2024) dilatih via self-supervised learning pada 142 juta gambar beragam domain, menghasilkan features yang robust dan domain-agnostic. DINO-IR (Lin et al., 2024) (Lin et al., 2024) secara eksplisit menunjukkan bahwa: (1) shallow features DINOv2 mengandung informasi pixel-level yang kaya; (2) deep features DINOv2 bersifat degradation-insensitive; dan (3) menggunakan DINOv2 sebagai guidance dalam restoration memberikan hasil lebih baik dibanding metode sebelumnya di berbagai task restoration.

3.6 Charbonnier Loss dalam Image Restoration

Charbonnier loss (pseudo-Huber) lebih robust terhadap outlier dibanding MSE dan menghasilkan detail lebih tajam. Dalam UIE dan restoration modern, Charbonnier digunakan sebagai loss utama di banyak metode: Restormer (CVPR 2022) menggunakannya sebagai loss rekonstruksi utama (Zamir et al., 2022), dan UWE-Net (Procedia Computer Science / IEEE Journal of Oceanic Engineering, 2021) menggunakan kombinasi CBAM dan Charbonnier loss untuk UIE.

4. Desain Arsitektur

4.1 Gambaran Umum Pipeline



4.2 NAFNet Backbone

Konfigurasi yang Dipakai

```
model: NAFNet
width: 32
enc_blks: [2, 2, 4, 8]
middle_blks: 12
dec_blks: [2, 2, 2, 2]
pretrained: NAFNet-SIDD-width32
```

Parameter total (width=32): ~17-20M.

Arsitektur NAF Block

Setiap NAF Block terdiri dari:

1. LayerNorm
2. Conv 1x1 — channel mixing
3. Depthwise Conv 3x3 — spatial feature extraction
4. **SimpleGate**: X dibagi dua menjadi X1 dan X2, output = X1 * X2 (element-wise)
5. Conv 1x1
6. **Simplified Channel Attention (SCA)**: Global Average Pooling + linear transform tanpa nonlinearitas
7. Residual connection

Mengapa Pretrained SIDD, bukan GoPro

NAFNet-SIDD-width32 belajar prior "clean image" yang umum (edge, tekstur, natural image statistics) yang lebih general untuk UIE. GoPro lebih spesifik ke motion blur, yang kurang relevan untuk underwater degradation. NAFNet dilatih pada patch 256x256 hasil crop, sehingga isu FOV GoPro tidak relevan untuk fine-tuning level patch.

4.3 PINN Branch: Beer-Lambert Underwater Physics

4.3.1 Model Fisika

```
I(x) = J(x) * t(x) + A * (1 - t(x))
t_c(x) = exp(-beta_c * d(x))
J(x) = (I(x) - A * (1 - t(x))) / t_safe(x)
t_safe(x) = max(t(x), 0.05)
```

Mengapa per-channel beta: Beer-Lambert secara fisika menyatakan atenuasi berbeda per panjang gelombang (beta_R >> beta_G > beta_B di air laut), yang merupakan penyebab utama color cast underwater. Ini membedakan framework kita dari HuWIE-Net yang menggunakan beta global (Eksioglu et al., 2025).

4.3.2 Estimasi Ambient Light A

A diestimasi dari input image menggunakan dark channel prior yang dimodifikasi untuk underwater:

1. Nonaktifkan channel merah (diserap paling cepat di air).
2. Ambil 0.1% piksel paling terang di dark channel.
3. A = nilai RGB maksimum dari piksel tersebut.

4.3.3 Arsitektur PINN Branch

```
Bottleneck features (B x Cb x Hb x Wb)
          |
   Global Average Pooling -> (B x Cb)
      /                     \
  beta Head              Depth Head
  Linear Cb->64          Linear Cb->64
  GELU                   GELU
  Linear 64->3           Linear 64->1
  Softplus (>0)          Sigmoid (0,1)
  beta_R, beta_G, beta_B      d
```

- **Softplus** untuk beta: memastikan nilai positif secara smooth tanpa gradient issue di nol.
- **Sigmoid** untuk d: membatasi kedalaman ke range (0,1) yang dinormalisasi.

4.4 DINOv2 Perceptual Head

DINOv2 backbone sepenuhnya **frozen** (tidak diupdate selama training). Perceptual loss:

```
L_percep = || f_DINO(J_phys) - f_DINO(J_GT) ||_F^2
```

5. Fungsi Loss

5.1 Total Loss

```
L_total = 1.0 * L_char + 0.1 * L_phys + 0.05 * L_percep
```

5.2 Charbonnier Loss (Reconstruction)

```
L_char = (1/N) * sum_i sqrt((J_phys_i - J_GT_i)^2 + eps^2),  eps = 1e-3
```

Charbonnier lebih robust terhadap outlier dibanding MSE. Digunakan sebagai standar di Restormer (Zamir et al., 2022) (CVPR 2022) dan metode UIE modern.

5.3 Physics Consistency Loss

```
I_recon = J_phys * t + A * (1 - t)
L_phys  = || I_recon - I_input ||_1
```

Memaksa J_phys, t, A konsisten dengan input I menurut Beer-Lambert. Didukung langsung oleh Pan et al. (2021) (IEEE TPAMI, 2021) dan BLUE-Net (Li et al., 2025) (Elsevier, 2025).

5.4 DINOv2 Perceptual Loss

```
L_percep = || f_DINO(J_phys) - f_DINO(J_GT) ||_F^2
```

DINOv2 dipilih karena features-nya domain-agnostic (Oquab et al., 2024)(Lin et al., 2024) dan lebih cocok untuk domain underwater dibanding VGG.

5.5 Justifikasi Bobot Loss

Loss	Bobot	Alasan
L_char	1.0	Objective utama; normalisasi skala
L_phys	0.1	Regularizer fisika; terlalu besar akan over-constrain model
L_percep	0.05	DINOv2 loss berskala lebih besar; bobot kecil untuk balance

6. Dataset

6.1 LSUI (Large-Scale Underwater Image Enhancement)

- **Total**: 5,004 pasangan gambar (paired: underwater input + reference).
- **Split**: Train (~3,879), Test-L400 (400 pasangan).
- **Resolusi**: Beragam; di-crop 256x256 saat training.
- **Referensi**: Peng et al. (2023), IEEE TIP 2023.

6.2 UIEB (Underwater Image Enhancement Benchmark)

- **Total**: 890 pasangan + 60 challenging (tanpa reference).
- **Eval**: Seluruh 890 pasangan (UIEB-890).
- **Referensi**: Li et al. (2020), IEEE TIP 2020.
- **Alasan**: Benchmark standard UIE paling banyak digunakan; memungkinkan perbandingan langsung dengan SOTA.

7. Setup Training

7.1 Hardware dan Mixed Precision

- **GPU**: NVIDIA A100 40GB
- **Mixed Precision**: Ya, torch.cuda.amp (Automatic Mixed Precision). Operasi berat di FP16 untuk kecepatan dan efisiensi VRAM; master weights dan accumulation tetap di FP32.

7.2 Hyperparameter

Parameter	Nilai	Justifikasi
Backbone	NAFNet width=32	~17-20M parameter, balance kapasitas vs. efisiensi
Pretrained	NAFNet-SIDD-width32	Prior clean image lebih general untuk UIE
Patch size	256x256	Standard UIE training patch
Batch size	16	Balance GPU utilization di A100
Optimizer	AdamW	Weight decay membantu generalisasi
LR backbone	3e-4 -> 1e-4	Differential LR: backbone fine-tune lebih perlahan
LR PINN head	1e-3	PINN dari scratch, butuh LR lebih tinggi
Weight decay	1e-4	Regularisasi ringan
Epochs	50-60	Cukup untuk konvergensi dengan pretrained
LR schedule	CosineAnnealing	Penurunan gradual untuk stabilitas akhir training

7.3 Strategi Fine-Tuning: Soft-Freeze Warmup

Epoch 1-2 (Warmup): Freeze shallow encoder stages. Train: decoder, bottleneck, PINN branch, output head. Tujuan: adaptasi komponen baru ke backbone tanpa merusak low-level features yang sudah dipelajari dari SIDD.

Epoch 3-60 (Full Fine-tuning): Unfreeze semua layer NAFNet dengan differential LR. DINOv2 tetap frozen sepanjang waktu.

Strategi ini konsisten dengan literature: Jiang et al. (2022) (Pattern Recognition, Elsevier, 2022) dan Wang et al. (Wang et al. (2023) sama-sama menunjukkan pentingnya menangani domain gap secara bertahap di UIE.

8. Metrik Evaluasi

8.1 PSNR

```
PSNR = 10 * log10(255^2 / MSE(J_pred, J_GT))
```

Target: PSNR > 22.91 dB di UIEB-890; PSNR > 24.16 dB di LSUI Test-L400.

8.2 SSIM

- Range [0, 1]; mengukur luminance, contrast, structure.
- Target: SSIM > 0.906 di LSUI Test-L400; SSIM > 0.820 di UIEB.
- Referensi: Wang et al. (Wang et al., 2004) (IEEE TIP, 2004).

8.3 UCIQE (No-Reference)

```
UCIQE = c1 * sigma_c + c2 * con_l + c3 * mu_s
```

Metrik NR-IQA khusus UIE; berguna untuk evaluasi di UIEB challenging set (60 gambar tanpa reference).
Referensi: Yang & Sowmya (Yang & Sowmya, 2015) (IEEE TIP, 2015).

8.4 Justifikasi Dua Benchmark

Eval Set	Ukuran	Tujuan
UIEB-890	890	Primary: paling banyak dipakai literature UIE
LSUI Test-L400	400	Secondary: in-domain validation; target PSNR >24 dB

9. Ablation Study

Varian	NAFNet	PINN	DINOv2	Keterangan
V1 (Baseline)	Ya	Tidak	Tidak	Pure NAFNet fine-tune
V2	Ya	Ya	Tidak	NAFNet + fisika saja
V3	Ya	Tidak	Ya	NAFNet + perceptual saja
V4 (Full)	Ya	Ya	Ya	Framework lengkap (proposed)

Semua varian: NAFNet-SIDD-width32, 50-60 epoch, batch 16, patch 256x256, AdamW. Setting identik untuk fair comparison.

Hipotesis: V4 > V2 > V1; V3 meningkatkan kualitas visual meski PSNR tidak selalu lebih tinggi dari V1.

10. Perbandingan dengan Metode Lain

Metode	Venue	PSNR UIEB	PSNR LSUI-L400	Params	Catatan
UDCP	IEEE TIP 2011	16.22	—	0	Non-learning, sering over-dehaze
FUnIE-GAN	IEEE RA-L 2020	21.20	~21.0	7.02M	GAN-based, cepat
HuWIE-Net	IEEE Access 2025	Competitive	—	0.56M	Beta global, sangat ringan
U-shape Transformer	IEEE TIP 2023	22.91	24.16	65.6M	SOTA LSUI, sangat berat
Restormer (percobaan tim)	CVPR 2022	~17 (tdk konvergen)	—	36.5M	Domain gap terlalu besar, 35 epoch

Metode	Venue	PSNR UIEB	PSNR LSUI-L400	Params	Catatan
Ours (V4)	—	Target >22.91	Target >24.16	~17-20M	Per-channel beta, transfer learning

11. Potensi Masalah dan Mitigasi

Masalah	Kemungkinan	Mitigasi
PINN: t mendekati nol -> NaN/Inf	Medium	Clamp t >= 0.05; Softplus untuk beta
L_phys dominan -> output over-smoothed	Medium	Jaga lambda_phys = 0.1; monitor tiap komponen
Underfitting LSUI (3.8k data)	Low	Pretrained NAFNet + augmentasi
Overfitting pola LSUI	Low-Medium	Eval di UIEB (out-of-distribution)
DINOv2 memory overhead	Medium	Frozen; no gradient; gradient checkpoint jika perlu

12. Roadmap Implementasi

1. **Persiapan** (1-2 hari): Setup environment, download pretrained NAFNet-SIDD-width32, preprocess LSUI + UIEB.
2. **Implementasi** (2-3 hari): Integrasi NAFNet + PINN Branch + DINOv2 loss + semua loss function.
3. **Training** (2-3 hari): V1 untuk sanity check, kemudian V4 full. Monitor val PSNR tiap epoch.
4. **Evaluasi** (1-2 hari): PSNR, SSIM, UCIQE di UIEB-890 dan LSUI Test-L400. Ablation V2, V3. Visualisasi.
5. **Laporan**: Dokumen ini sebagai basis Introduction, Related Work, Methodology, dan Experiments.

13. Referensi

> **Catatan**: Seluruh referensi diprioritaskan terbitan 2021–2026. Referensi sebelum 2021 hanya digunakan untuk sumber yang bersifat foundational/seminal (model fisika, metrik, konsep dasar) yang tidak ada penggantinya. Dua referensi arXiv digunakan karena tidak ditemukan publikasi peer-reviewed yang secara spesifik membahas DINOv2 untuk image restoration.

Jurnal IEEE

UNCTAD (2025). "Global Trade Update (June 2025): Sustainable Ocean Economy," United Nations Conference on Trade and Development, 2025.

Singh, S. et al. (2023). et al., "Autonomous Underwater Vehicles: Identifying Critical Issues and Future Perspectives in Image Acquisition," *Sensors*, vol. 23, no. 12, 2023. DOI: 10.3390/s23125619.

Jaffe, J.S. (1990). "Computer Modeling and the Design of Optimal Underwater Imaging Systems," *IEEE Journal of Oceanic Engineering*, vol. 15, no. 2, pp. 101–111, 1990. DOI: 10.1109/48.50695.
(Foundational — satu-satunya sumber model fisika Beer-Lambert/Jaffe-McGlamery underwater)

He, K., Sun, J., and Tang, X. (2011). J. Sun, and X. Tang, "Single Image Haze Removal Using Dark Channel Prior," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 33, no. 12, pp. 2341–2353, 2011. DOI: 10.1109/TPAMI.2010.168.
(Foundational — DCP yang mendasari estimasi ambient light)

Islam, M.J., Xia, Y., and Sattar, J. (2020). Y. Xia, and J. Sattar, "Fast Underwater Image Enhancement for Improved Visual Perception," *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 3227–3234, 2020. DOI: 10.1109/LRA.2020.2974710.

Eksioglu, E.M. et al. (2025). et al., "Joint Optimization in Underwater Image Enhancement: A Training Framework Integrating Pixel-Level and Physical-Channel Techniques," *IEEE Access*, vol. 13, pp. 1–1, 2025. DOI: 10.1109/ACCESS.2025.3536173.

Peng, L., Zhu, C., and Bian, L. (2023). "U-Shape Transformer for Underwater Image Enhancement," *IEEE Transactions on Image Processing*, vol. 32, pp. 3066–3079, 2023. DOI: 10.1109/TIP.2023.3276332.

Wang, Z. et al. (2023). "Domain Adaptation for Underwater Image Enhancement," *IEEE Transactions on Image Processing*, vol. 32, pp. 1442–1457, 2023. DOI: 10.1109/TIP.2023.3244647.

Pan, J. et al. (2021). et al., "Physics-Based Generative Adversarial Models for Image Restoration and Beyond," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 7, pp. 2449–2462, 2021. DOI: 10.1109/TPAMI.2020.2969348.

Li, C. et al. (2020). et al., "An Underwater Image Enhancement Benchmark Dataset and Beyond," *IEEE Transactions on Image Processing*, vol. 29, pp. 4376–4389, 2020. DOI: 10.1109/TIP.2019.2955241.
(Dataset UIEB — foundational)

Wang, Z. et al. (2004). "Image Quality Assessment: From Error Visibility to Structural Similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004. DOI: 10.1109/TIP.2003.819861.
(Foundational — metrik SSIM)

Yang, M. and Sowmya, A. (2015). and A. Sowmya, "An Underwater Color Image Quality Evaluation Metric," *IEEE Transactions on Image Processing*, vol. 24, no. 12, pp. 6062–6071, 2015. DOI: 10.1109/TIP.2015.2491020.
(Foundational — metrik UCIQE, tidak ada pengganti yang lebih baru)

Jurnal Elsevier

Xu, S. et al. (2023). et al., "Deep Learning-based Underwater Image Enhancement: A Review," *Neurocomputing*, vol. 527, pp. 204–232, 2023. DOI: 10.1016/j.neucom.2023.01.009.

Guo, F. et al. (2024). et al., "Algorithms for Improving the Quality of Underwater Optical Images: A Comprehensive Review," *Signal Processing: Image Communication*, Elsevier, 2024. DOI:

10.1016/j.sigpro.2024.109408.

Jiang, Q. et al. (2022). et al., "Two-step domain adaptation for underwater image enhancement," *Pattern Recognition*, vol. 122, p. 108324, Elsevier, 2022. DOI: 10.1016/j.patcog.2021.108324.

Li et al. (2025). (BLUE-Net) W. Li et al., "Physics-driven prior learning-based deep unrolling for underwater image enhancement," *Engineering Applications of Artificial Intelligence*, Elsevier, 2025. DOI: 10.1016/j.engappai.2025.109xxx.

Zhang et al. (2025). (UPMC-Net) S. Zhang et al., "UPMC-Net: Underwater Physical Model Constraint Network for underwater image enhancement," *Digital Signal Processing*, Elsevier, 2025. DOI: 10.1016/j.dsp.2025.104xxx.

Jurnal Lain (Peer-Reviewed)

Paull, J. et al. (2025). et al., "Underwater image enhancement using generative adversarial networks: a survey," *International Journal of Communication Systems*, Tandfonline, 2025. DOI: 10.1080/1206212X.2025.2466197.

Oquab, M. et al. (2024). et al., "DINOv2: Learning Robust Visual Features without Supervision," *Transactions on Machine Learning Research (TMLR)*, 2024. URL: https://openreview.net/forum?id=a68SUt6zFt.

Conference Peer-Reviewed

Zamir, S.W. et al. (2022). et al., "Restormer: Efficient Transformer for High-Resolution Image Restoration," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5718–5729, 2022.

Chen, L. et al. (2022). et al., "Simple Baselines for Image Restoration," in *Proc. European Conference on Computer Vision (ECCV)*, Springer LNCS, pp. 17–33, 2022.

Johnson, J., Alahi, A., and Fei-Fei, L. (2016)., A. Alahi, and L. Fei-Fei, "Perceptual Losses for Real-Time Style Transfer and Super-Resolution," in *Proc. European Conference on Computer Vision (ECCV)*, Springer LNCS, 2016.
(Foundational — konsep perceptual loss, tidak ada pengganti yang lebih baru untuk konsep dasar ini)

arXiv (digunakan karena tidak ada published paper yang secara spesifik membahas DINOv2 untuk image restoration)

Lin, X. et al. (2024). et al., "Multi-task Image Restoration Guided By Robust DINO Features (DINO-IR)," arXiv:2312.01677, 2024. *(Paling relevan untuk justifikasi DINOv2 dalam restoration; belum ada versi jurnal yang dipublikasikan)*