ITS
Institut
Teknologi
Sepuluh Nopember

LAPORAN FINAL PROJECT

RETRIEVAL AUGMENTED PARAMETER EFFICIENT CROSS LINGUAL ADAPTION OF MEDICAL LLMs FOR INDONESIAN CLINICAL QUESTION ANSWERING

FAIZ AKBAR HIZBULLAH

NRP 5054241005

SHABRINA SARAYATI

NRP 5054241009

SULTAN HAMDI JAILANI DAULAY

NRP 5054241013

MUHAMMAD DAYYAN GHAZANFAR LATIEF

NRP 5054241036

SITTI AMINAH

NRP 5054241041

Dosen Pengampu

Dini Adni Navastara, S.Kom, M.Sc.

NIP 198510172015042001

Program Studi Rekayasa Kecerdasan Artifisial

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

Tahun 2026

LAPORAN FINAL PROJECT

RETRIEVAL AUGMENTED PARAMETER EFFICIENT CROSS LINGUAL ADAPTION OF MEDICAL LLMs FOR INDONESIAN CLINICAL QUESTION ANSWERING

FAIZ AKBAR HIZBULLAH

NRP 5054241005

SHABRINA SARAYATI

NRP 5054241009

SULTAN HAMDI JAILANI DAULAY

NRP 5054241013

MUHAMMAD DAYYAN GHAZANFAR LATIEF

NRP 5054241036

SITTI AMINAH

NRP 5054241041

Dosen Pengampu

Dini Adni Navastara, S.Kom, M.Sc.

NIP 198510172015042001

Program Studi Rekayasa Kecerdasan Artifisial

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

Tahun 2026

ABSTRAK

Retrieval-Augmented Parameter-Efficient

Cross-Lingual Adaptation of Medical LLMs for Indonesian Clinical Question Answering

Nama Mahasiswa / NRP	**:**	**Faiz Akbar Hizbullah / 5054241005** **Shabrina Sarayati / 5054241009** **Sultan Hamdi Jailani Daulay / 5054241013** **Muhammad Dayyan Ghazanfar Latief / 5054241036** **Sitti Aminah / 5054241041**
Departemen	**:**	**Teknik Informatika FTEIC - ITS**
Dosen Pengampu	**:**	**Dini Adni Navastara, S.Kom, M.Sc.**

Abstrak

Ketimpangan rasio dokter terhadap penduduk di Indonesia (1:1.416, di bawah standar WHO 1:1.000) serta persebaran tenaga medis yang tidak merata mendorong kebutuhan sistem penyedia informasi kesehatan awal yang mudah diakses. Penelitian ini mengembangkan dan membandingkan tiga *Large Language Model* (LLM) dengan filosofi *pre-trained* berbeda , BioMistral-7B (*domain-first*), Qwen2.5-7B-Instruct (*language-first*), dan Gemma-SEA-LION-9B-IT (*regional-first*) yang di-*fine-tune* menggunakan QLoRA pada dataset hasil *web scraping* forum konsultasi Alodokter (58.940 pasangan keluhan-jawaban), untuk tugas *Medical Question Answering* berbahasa Indonesia. Ketiga model selanjutnya ditingkatkan dengan *Hybrid Retrieval-Augmented Generation* (RAG), menggabungkan *dense retrieval* (multilingual-E5-large-instruct) dan BM25 (bobot 0,6:0,4). Evaluasi menggunakan enam metrik (Token-F1, BLEU, ROUGE-L, BERTScore, *semantic similarity*, *NLI faithfulness*) dan uji Wilcoxon *signed-rank*. Hasil menunjukkan QLoRA meningkatkan performa ketiga modeln, dengan peningkatan terbesar pada BioMistral. Qwen2.5 dan SEA-LION secara konsisten mengungguli BioMistral, mendukung hipotesis bahwa penguasaan bahasa target lebih menentukan kualitas jawaban dibandingkan pengetahuan domain medis berbahasa Inggris. SEA-LION terpilih sebagai model terbaik untuk tahap RAG, namun penambahan RAG menghasilkan efek netral secara statistik, dengan skor *faithfulness* 0,36 0,45 yang mengindikasikan keterbatasan kualitas *retrieval* (recall@3 0,5751) sebagai faktor penghambat utama. Sistem akhir diimplementasikan sebagai bot Telegram bernama Medi AI untuk demonstrasi dan edukasi kesehatan masyarakat. Penelitian ini berkontribusi pada pemahaman strategi adaptasi LLM medis untuk *low-resource language* serta menegaskan pentingnya evaluasi empiris terhadap efektivitas RAG.

Kata kunci: Large Language Model, QLoRA, Retrieval-Augmented Generation, Medical Question Answering, Cross-Lingual Adaptation

DAFTAR ISI

BAB 1 PENDAHULUAN 8
1.1 Latar Belakang 8
1.2 Rumusan Masalah 9
1.3 Batasan Masalah 9
1.4 Tujuan dan Manfaat 9
1.4.1 Tujuan 9
1.4.2 Manfaat 9
Penelitian ini memberikan beberapa manfaat sebagai berikut 9
BAB 2 TINJAUAN PUSTAKA 11
2.1 Penelitian Terkait 11
2.2 Dasar Teori 13
2.2.1 Large Language Model dan Arsitektur Transformer 14
2.2.2 Fine-tuning dan Parameter-Efficient Fine-Tuning (PEFT) 14
2.2.3 LoRA dan QLoRA 15
2.2.4 Retrieval-Augmented Generation (RAG) 16
2.2.5 Dense Retrieval dan Sentence Embedding 16
2.2.6 Sparse Retrieval (BM25) dan Hybrid Search 17
2.2.7 Model Pra-terlatih yang Digunakan 18
2.2.8 Metrik Evaluasi 19
BAB 3 METODOLOGI 22
3.1 Perancangan Sistem 22
3.2 Implementasi Sistem 23
3.2.1 Pengumpulan Data 23
3.2.2 Pembersihan dan Kurasi Data 23
3.2.3 Pembagian dan Format Data Latih 24
3.2.4 Fine-tuning dengan QLoRA 24
3.2.5 Pembangunan Index RAG 25
BAB 4 HASIL DAN PEMBAHASAN 27
1.4 Konfigurasi Lingkungan Penelitian 27
1.5 Hasil Penelitian 27
1.5.1 Skenario 1 - Efektivitas Fine-tuning QLoRA 27
1.5.2 Skenario 2 - Kontribusi RAG 29
1.5.3 Skenario 3 - Kualitas Retrieval 31
1.5.4 Contoh Kualitatif 32
1.6 Pembahasan 32
1.7 Deployment 33
BAB 5 KESIMPULAN 34

DAFTAR GAMBAR

Gambar 3.1 Diagram alur sistem..... 20
Gambar 4.1 Tampilan bot Medi AI pada platform Telegram.....33

DAFTAR TABEL

Tabel 2.1 Perbandingan Penelitian Terkait.....10
Tabel 2.2 Perbandingan antarmodel.....17
Tabel 4.1 Rangkuman spesifikasi lengkap lingkungan penelitian.....25
Tabel 4.2 Skor metrik base vs fine-tuned (n=100).....26
Tabel 4.3 Uji signifikansi base → fine-tuned (Wilcoxon signed-rank, p<0,05 = *).....27
Tabel 4.4 Skor fine-tuned vs fine-tuned + rag.....28
Tabel 4.5 Uji signifikansi fine-tuned → fine-tuned + rag (Wilcoxon, p<0,05 = *).....29
Tabel 4.6 Perbandingan performa retrieval (top-k).....30
Tabel 4.7 Ablasi komponen retrieval.....30
Tabel 4.8 Variasi bobot hybrid.....31
Tabel 4.9 Perbandingan hasil kualitatif jawaban.....32

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Akses terhadap layanan kesehatan yang memadai masih menjadi tantangan besar di Indonesia. Salah satu penyebabnya adalah ketimpangan antara jumlah dokter dan jumlah penduduk. Berdasarkan data dari Kementerian Kesehatan (SISDMK, 1 Mei 2026), jumlah penduduk di Indonesia mencapai 288.315.089 jiwa dan hanya dilayani oleh 203.571 dokter, sehingga rasio dokter terhadap penduduk adalah 1 : 1.416. Angka ini masih jauh dari standar ideal yang ditetapkan oleh *World Health Organization* (WHO) yaitu 1 dokter untuk setiap 1.000 penduduk. Selain itu, persebaran dokter di Indonesia juga belum merata, dimana sebagian besar tenaga medis masih terkonsentrasi di Pulai Jawa, sementara wilayah timur Indonesia masih kekurangan tenaga medis.

Disisi lain, perkembangan *Large Language Model* (LLM) menunjukkan potensi yang besar dalam membantu penyediaan informasi, termasuk informasi medis. Penelitian oleh Lievin dkk. menunjukkan bahwa model seperti InstructGPT dan Codex mampu mencapai ambang batas performa minimum pada berbagai *benchmark* medis, seperti MedQA-USMLE, MedMCQA, dan PubMedQA. Bahkan, model opensource seperti 2 70B juga mampu melampaui batas kelulusan USMLE. Hal ini menunjukkan bahwa LLM dapat memahami dan memproses pengetahuan medis dengan cukup baik, meskipun masih memiliki keterbatasan, seperti bias pada urutan jawaban dan kurangnya pemahaman pada domain tertentu.

Untuk domain medis, Labrak dkk. mengembangkan BioMistral, yaitu model berbasis Mistral 7B yang dilatih ulang menggunakan data medis dari PubMed Central. Model ini terbukti memiliki performa yang lebih baik dibandingkan beberapa model medis open-source lainnya, seperti PMC-LLaMA, MediTron, dan MedAlpaca, terutama pada tugas tanya jawab medis berbahasa Inggris. Namun, performa BioMistral cenderung menurun ketika digunakan dalam bahasa selain Inggris, termasuk Bahasa Indonesia.

Sebagai perbandingan, Qwen Team mengembangkan Qwen2.5 yang dilatih dengan data dalam jumlah besar dan menunjukkan performa yang baik dalam berbagai bahasa, termasuk Bahasa Indonesia. Selain itu, AI Singapore mengembangkan SEA-LION, model yang secara khusus dioptimalkan untuk bahasa-bahasa Asia Tenggara, termasuk Bahasa Indonesia, sehingga memiliki kemampuan pemahaman bahasa yang lebih sesuai dengan konteks regional.

Perbedaan karakteristik dari ketiga model tersebut menimbulkan pertanyaan mengenai model mana yang paling efektif untuk tugas tanya jawab medis dalam Bahasa Indonesia. Oleh karena itu, penelitian ini melakukan fine-tuning menggunakan metode Quantized Low-Rank Adaptation (QLoRA) pada tiga model, yaitu BioMistral-7B, Qwen2.5-7B-Instruct, dan Gemma-SEA-LION-9B-IT, menggunakan dataset hasil web scraping dari forum kesehatan Alodokter. Selanjutnya, ketiga model akan ditingkatkan menggunakan metode Retrieval-Augmented Generation (RAG), yang telah terbukti mampu meningkatkan akurasi model dalam tugas medis.

1.2 Rumusan Masalah

Dalam penelitian ini, dirumuskan beberapa pertanyaan utama yang menjadi fokus untuk dianalisis, yaitu:

1. Bagaimana efektivitas proses fine-tuning menggunakan metode QLoRA pada model BioMistral 7B, Qwen2.5-7B-Instruct, Gemma-SEA-LION-9B-IT untuk beradaptasi dengan dataset medis klinis berbahasa Indonesia?
2. Seberapa besar peningkatan kualitas dan akurasi jawaban sistem Medical Question Answering setelah mengintegrasikan metode Retrieval-Augmented Generation (RAG) pada ketiga model yang telah di-fine-tune?
3. Bagaimana konfigurasi hybrid retrieval yang optimal, ditinjau dari perbandingan antara dense retrieval, BM25, dan kombinasi keduanya berdasarkan metrik peringkat standar?

1.3 Batasan Masalah

Batasan masalah dari penelitian ini adalah:

1. Sistem yang dibangun difokuskan pada tugas Question Answering berbasis teks dalam Bahasa Indonesia, tidak mencakup modalitas lain seperti gambar medis atau data rekam medis terstruktur.
2. Dataset yang digunakan bersumber dari hasil web scraping forum konsultasi kesehatan Alodokter, sehingga cakupan topik medis terbatas pada jenis keluhan yang tersedia pada platform tersebut.

1.4 Tujuan dan Manfaat

Penelitian ini memiliki tujuan dan manfaat yang dirancang untuk memberikan kontribusi baik dalam aspek akademis maupun praktis.

1.4.1 Tujuan

Tujuan dari penelitian ini diantaranya

1. Membandingkan efektivitas fine-tuning QLoRA pada tiga model dasar (BioMistral-7B, Qwen2.5-7B-Instruct, Gemma-SEA-LION-9B-IT) untuk tugas Medical Question Answering berbahasa Indonesia.
2. Membandingkan performa sistem dengan dan tanpa penerapan RAG guna mengukur kontribusi metode tersebut terhadap kualitas jawaban.
3. Mengimplementasikan sistem yang telah dikembangkan dalam bentuk bot Telegram agar informasi kesehatan dapat diakses secara mudah oleh masyarakat luas.

1.4.2 Manfaat

Penelitian ini memberikan beberapa manfaat sebagai berikut

1. Manfaat Teoritis
   Penelitian ini memberikan kontribusi dalam perbandingan adaptasi *Large Language Model* (LLM) untuk domain medis pada bahasa indonesia dengan sumber daya yang terbatas (*low resource*), yaitu antara pendekatan domain-first (seperti BioMistral) dan pendekatan language-first (seperti Qwen2.5 dan SEA-LION). Hasil penelitian ini diharapkan dapat menjadi rujukan dalam pengembangan model tanya jawab medis

berbahasa Indonesia, serta dalam kajian lanjutan mengenai efektivitas metode QLoRA dan Retrieval-Augmented Generation (RAG).

2. Manfaat Praktis
   Bagi masyarakat umum, sistem yang dikembangkan diharapkan dapat menjadi sarana memperoleh informasi kesehatan awal secara cepat, terutama bagi masyarakat di wilayah dengan keterbatasan akses tenaga medis. Bagi dunia akademik dan pengembang teknologi kesehatan, hasil perbandingan model ini dapat menjadi acuan praktis dalam memilih strategi adaptasi LLM medis untuk bahasa-bahasa lain di kawasan Asia Tenggara di masa mendatang.

BAB 2 TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Penelitian oleh Hanami, Mahendra, dan Wicaksono (2025) dalam *Semantic Classification of Indonesian Consumer Health Question* membahas permasalahan utama dalam forum kesehatan berbahasa Indonesia, yaitu keterbatasan tenaga medis dalam menjawab pertanyaan pengguna secara cepat. Untuk mengatasi hal tersebut, mereka membangun dataset berisi 946 pertanyaan kesehatan yang telah dianotasi, serta mengusulkan metode dua tahap untuk mengklasifikasikan tipe semantik dari pertanyaan.

Tujuan dari penelitian ini adalah membantu sistem memahami maksud dari pertanyaan pasien agar dapat diarahkan ke informasi yang relevan. Meskipun penelitian tersebut berfokus pada klasifikasi, bukan pembuatan jawaban, relevansinya terletak pada kesamaan masalah yang diangkat, yaitu keterbatasan data medis berbahasa indonesia dan kebutuhan akan sistem tanya jawab yang otomatis. Penelitian ini masih berhenti pada tahap pertanyaan, sehingga belum menghasilkan jawaban. Oleh karena itu, penelitian ini melanjutkan dengan menambahkan tahap generasi jawaban menggunakan LLM yang dipadukan dengan RAG.

Selanjutnya, Firdaus, Sumardi, dan Kulsum (2024) dalam *Integrating Retrieval-Augmented Generation with Large Language Model Mistral 7B for Indonesian Medical Herb* mengusulkan penggunaan RAG dengan model Mistral 7B untuk menghasilkan jawaban secara langsung pada domain tanaman obat. Penelitian ini memanfaatkan pengetahuan tentang ribuan tanaman obat di Indonesia sebagai basis data yang diambil saat proses retrieval.

Hasil penelitian tersebut menunjukkan bahwa kombinasi RAG dan model LLM dapat diterapkan pada domain medis berbahasa Indonesia. Namun, terdapat beberapa keterbatasan, seperti penggunaan basis pengetahuan yang statis, hanya berfokus pada satu subdomain, serta tidak adanya proses fine-tuning model. Oleh karena itu, penelitian ini mengembangkan pendekatan tersebut dengan menggunakan data nyata dari forum dokter–pasien, membandingkan beberapa model, serta menerapkan fine-tuning menggunakan QLoRA.

Labrak dkk. (2024) melalui BioMistral menggunakan pendekatan *domain-first*, yaitu dengan melatih ulang model Mistral 7B pada data biomedis berbahasa Inggris dari PubMed Central. Model ini kemudian diuji pada berbagai tugas QA medis dan juga diuji kemampuannya pada beberapa bahasa lain melalui terjemahan otomatis.

Hasilnya menunjukkan bahwa performa yang tinggi pada bahasa Inggris tidak sepenuhnya terbawa ke bahasa lain. Ketika diuji lintas bahasa, terjadi penurunan performa yang cukup signifikan, termasuk perbedaan akurasi yang cukup besar antarbahasa. Meskipun metode seperti model merging (DARE, TIES, SLERP) dapat membantu meningkatkan performa lintas bahasa, hasilnya tetap belum menyamai performa pada bahasa Inggris. Selain itu, bahasa Indonesia juga belum termasuk dalam evaluasi mereka.

Hal ini menjadi dasar bagi penelitian ini untuk membandingkan dua pendekatan, yaitu *domain-first* (model yang kuat di domain medis tetapi berbasis bahasa Inggris) dan *language-first* (model yang lebih dekat dengan konteks bahasa tertentu), khususnya untuk QA medis berbahasa Indonesia.

Selanjutnya, Paiola dkk. (2025) meneliti adaptasi LLM medis ke bahasa Portugis sebagai bahasa non-Inggris dengan sumber daya menengah. Mereka menggunakan dataset medis berbahasa Inggris yang diterjemahkan ke Portugis, lalu melakukan fine-tuning pada model menggunakan metode PEFT-QLoRA untuk membangun asisten medis virtual.

Hasil penelitian menunjukkan bahwa model yang sudah memiliki pengetahuan medis sebelumnya cenderung memberikan performa terbaik. Sementara itu, model yang di-*fine-tuning* khusus pada data Portugis mengalami penurunan pada pengetahuan medis sebelumnya (*catastrophic forgetting*), meskipun dari sisi bahasa menjadi lebih baik dan lebih natural.

Temuan ini menunjukkan bahwa adaptasi ke bahasa lokal itu penting, tetapi ada *trade-off* antara kemampuan bahasa dan pemahaman domain medis. Namun, penelitian tersebut tidak menggunakan RAG, tidak membahas bahasa Indonesia, dan tidak membandingkan pendekatan *domain-first* dan *language-first*. Oleh karena itu, penelitian ini mencoba melengkapi kekurangan tersebut dengan menggabungkan QLoRA, RAG, serta membandingkan beberapa model pada konteks bahasa Indonesia.

Penelitian oleh Xiong dkk. (2024) dalam *Benchmarking Retrieval-Augmented Generation for Medicine* memperkenalkan benchmark MIRAGE untuk mengevaluasi performa RAG pada berbagai konfigurasi sistem QA medis. Mereka menemukan bahwa penggunaan RAG tidak selalu meningkatkan performa, dan hasilnya sangat bergantung pada kualitas data dan komponen retrieval.

Temuan ini penting karena menunjukkan bahwa RAG perlu diuji berdasarkan data nyata, bukan langsung diasumsikan selalu lebih baik. Namun, penelitian tersebut hanya menggunakan data berbahasa Inggris, sehingga belum menjawab bagaimana performa RAG pada konteks bahasa Indonesia. Oleh karena itu, penelitian ini mencoba mengisi celah tersebut dengan menggunakan data dari forum dokter–pasien berbahasa Indonesia.

Tabel 2.1 Perbandingan Penelitian Terkait

No.	Penulis	Metode	Bahasa /Domain	Dataset	Hasil Utama	Keterbatasan
1	Hanami, Mahendra & Wicaksono (2025)	Klasifikasi *semantic type* pertanyaan (*two-step approach*)	Indonesia / kesehatan	964 pertanyaan forum kesehatan	Skema anotasi yang telah divalidasi oleh ahli, serta model untuk mengklasifikasikan maksud pertanyaan	Meskipun mampu memahami pertanyaan, sistem yang dikembangkan belum menghasilkan jawaban sebagai output akhir
2	Firdaus, Sumardi & Kulsum (2024)	RAG + Mistral 7B (tanpa *fine-tuning*)	Indonesia / tanaman obat	Basis pengetahuan tanaman obat Indonesia	Sistem QA generatif untuk herbal terbukti layak	Pendekatan yang digunakan masih bergantung pada knowledge base statis dengan ruang lingkup sempit, serta belum menerapkan adaptasi parameter pada model
3	Labrak dkk. (2024) BioMistral	*Continued pre-training* (domain-first	Inggris (+ 7 bahasa lain, evaluasi)	10 tugas QA medis;	Menunjukkan performa yang unggul pada	Bahasa Indonesia tidak dievaluasi

		) + QLoRA + *model merging*		benchmark multibahasa	benchmark berbahasa Inggris, namun mengalami penurunan signifikan ketika diuji pada bahasa lain	
4	Paiola dkk. (2025)	*Fine-tuning* (PEFT-QLoRA) pada data medis terjemahan	Portugis Brasil / medis umum	HealthCare Magic-100k-en & MedQuAD (terjemahan)	Hasil penelitian menunjukkan bahwa adaptasi bahasa merupakan faktor penting, namun ditemukan adanya fenomena *catastrophic forgetting* pada model turunan	Tanpa penerapan RAG, dan tanpa perbandingan strategi domain-first dan language-first
5	Xiong dkk. (2024) MIRAGE	Benchmark sistematis komponen RAG	inggris / medis umum	7.663 pertanyaan, 5 dataset QA medis	Penggunaan RAG tidak selalu meningkatkan akurasi, karena sangat bergantung pada kualitas komponen retrieva	Penelitian ini menggunakan data berbahasa Inggris

Berdasarkan pemetaan pada Tabel 2.1, terdapat tiga celah utama dalam penelitian sebelumnya. Pertama, dari sisi domain dan bahasa, penelitian QA medis berbahasa Indonesia (Hanami dkk., 2025; Firdaus dkk., 2024) masih terbatas pada tahap pemahaman pertanyaan atau hanya berfokus pada satu subdomain tertentu, seperti tanaman obat, dengan basis pengetahuan yang statis. Penelitian tersebut juga belum banyak menggunakan data klinis dari forum dokter–pasien secara luas

Kedua, dari sisi adaptasi model, penelitian terkait LLM medis lintas bahasa (Labrak dkk., 2024; Paiola dkk., 2025) menunjukkan bahwa keunggulan model pada satu bahasa atau domain tidak selalu berlaku pada konteks lain. Namun, penelitian tersebut belum menguji secara langsung pada bahasa Indonesia dan belum membandingkan secara sistematis pendekatan *domain-first* dan *language-first*.

Ketiga, dari sisi penggunaan RAG, penelitian oleh Xiong dkk. (2024) menunjukkan bahwa RAG tidak selalu meningkatkan performa dan sangat bergantung pada kualitas retriever dan korpus yang digunakan. Namun, pengujian tersebut masih terbatas pada data berbahasa Inggris.

2.2 Dasar Teori

Bagian ini memuat landasan teoritis yang mendasari penelitian, mencakup konsep-konsep utama dalam bidang pemrosesan bahasa alami (*Natural Language Processing*), serta pendekatan dan teknologi yang digunakan dalam pengembangan sistem *Large Language Model* (LLM) berbasis *fine-tuning* dan *Retrieval-Augmented Generation* (RAG) untuk *question answering* klinis berbahasa Indonesia, sebagai berikut:

2.2.1 Large Language Model dan Arsitektur Transformer

Large Language Model (LLM) adalah model bahasa berskala besar dengan jumlah parameter mencapai miliaran hingga ratusan miliar, yang dilatih secara *self-supervised* pada korpus teks berukuran masif untuk mempelajari distribusi probabilitas kata atau token berikutnya dalam suatu urutan. Kemampuan LLM dalam memahami konteks dan menghasilkan teks yang koheren bersumber dari arsitektur Transformer, yang diperkenalkan sebagai alternatif terhadap arsitektur rekuren (RNN/LSTM) dengan mengandalkan sepenuhnya mekanisme *self-attention* untuk memodelkan ketergantungan antar token tanpa batasan urutan sekuensial (Vaswani dkk., 2017).

Secara arsitektural, LLM generatif modern termasuk ketiga model yang digunakan dalam penelitian ini mengadopsi varian *decoder-only* dari Transformer, di mana model memprediksi token berikutnya secara autoregresif berdasarkan token-token sebelumnya, dengan mekanisme *self-attention* yang memungkinkan setiap token memperhatikan representasi token lain dalam konteksnya secara dinamis. Sebelum diproses oleh model, teks input terlebih dahulu dipecah menjadi unit-unit *subword* melalui proses tokenisasi (misalnya Byte-Pair Encoding atau SentencePiece), yang memungkinkan model menangani kosakata terbuka termasuk kata-kata di luar kamus tanpa kehilangan informasi morfologis.

Dalam penelitian ini, ketiga model dasar yang dipilih untuk eksperimen BioMistral-7B, Qwen2.5-7B-Instruct, dan Gemma-SEA-LION-9B-IT seluruhnya merupakan LLM berarsitektur Transformer *decoder-only*. Kesamaan fondasi arsitektural ini menjadi prasyarat penting yang memungkinkan ketiganya diadaptasi melalui mekanisme *fine-tuning* yang seragam (dibahas pada subbab 2.2.2-2.2.3) serta menghasilkan jawaban dalam format teks bebas (*free-text generation*) yang dibutuhkan untuk menjawab pertanyaan klinis berbahasa Indonesia.

2.2.2 Fine-tuning dan Parameter-Efficient Fine-Tuning (PEFT)

Fine-tuning adalah proses adaptasi model bahasa yang telah dilatih sebelumnya (*pre-trained*) terhadap tugas atau domain spesifik dengan melanjutkan pelatihan pada data yang relevan. Pendekatan *full fine-tuning* melakukan pembaruan terhadap seluruh parameter model, yang pada LLM berskala miliaran parameter menjadi sangat mahal secara komputasi: selain bobot model itu sendiri, proses ini juga mengharuskan penyimpanan *gradient* dan *optimizer state* (misalnya momentum dan varians pada optimizer Adam) untuk setiap parameter yang dilatih, sehingga kebutuhan memori dapat membengkak hingga beberapa kali lipat ukuran model dasar (Hu dkk., 2021).

Sebagai alternatif, *Parameter-Efficient Fine-Tuning* (PEFT) membekukan (*freeze*) sebagian besar atau seluruh bobot model dasar, dan hanya melatih sejumlah kecil parameter tambahan yang disisipkan ke dalam arsitektur. Beberapa keluarga metode PEFT yang dikenal luas antara lain *adapter tuning* (menyisipkan lapisan kecil di antara blok Transformer), *prefix-tuning* (menambahkan vektor terlatih pada awal urutan input), dan *Low-Rank Adaptation* (LoRA) yang merepresentasikan pembaruan bobot melalui dekomposisi matriks berderajat rendah.

Dalam penelitian ini, model dasar yang digunakan berukuran 7–9 miliar parameter, yang pada perangkat keras GPU dengan kapasitas memori terbatas tidak memungkinkan dilakukannya *full fine-tuning* tanpa infrastruktur multi-GPU berskala besar. Atas dasar keterbatasan sumber daya komputasi inilah penelitian ini memilih pendekatan PEFT, secara spesifik menggunakan metode LoRA dan QLoRA yang dijabarkan lebih rinci pada subbab 2.2.3.

2.2.3 LoRA dan QLoRA

LoRA adalah metode PEFT yang didasarkan pada hipotesis bahwa pembaruan bobot selama adaptasi tugas memiliki "*intrinsic rank*" yang rendah, sehingga dapat direpresentasikan secara efisien melalui dekomposisi matriks berderajat rendah (*low-rank decomposition*) (Hu dkk., 2021). Alih-alih memperbarui matriks bobot $W_0 \in R^{d\,x\,k}$ secara langsung, LoRA membekukan W_0 dan menambahkan pembaruan $\Delta W = BA$, dengan $B \in R^{d\,x\,r}$ dan $A \in R^{r\,x\,k}$, di mana rank $r \ll min(d, k)$. Forward pass yang semula $h = W_0 x$ menjadi:

$$h = W_0 x + \Delta W x = W_0 x + (\frac{\alpha}{r}) BAx$$

dengan α adalah konstanta penskalaan (*scaling factor*). Matriks A diinisialisasi secara acak menggunakan distribusi Gaussian, sedangkan B diinisialisasi dengan nol, sehingga $\Delta W = BA$ bernilai nol pada awal pelatihan dan model berperilaku identik dengan model dasar sebelum adaptasi dimulai. Hanya matriks A dan B yang diperbarui selama pelatihan, sementara W_0 tetap beku sehingga jumlah parameter yang dilatih dapat ditekan hingga kurang dari 1% dari total parameter model.

Beberapa hyperparameter kunci dalam LoRA meliputi: rank r (menentukan kapasitas matriks adaptasi semakin besar r , semakin besar kapasitas representasi namun semakin besar pula jumlah parameter terlatih), alpha α (mengatur skala kontribusi ΔW terhadap output), *target modules* (lapisan linear mana dalam arsitektur Transformer yang disisipi adapter, misalnya `q_proj`, `v_proj`, atau seluruh lapisan *attention* dan *feed-forward*), serta *dropout* (regularisasi untuk mencegah *overfitting* pada parameter adapter).

QLoRA memperluas LoRA dengan mengkuantisasi bobot model dasar ke presisi 4-bit menggunakan tipe data 4-bit NormalFloat (NF4) sebuah tipe data yang secara teori-informasi optimal untuk bobot yang terdistribusi normal dengan rata-rata nol, di mana setiap *bin* kuantisasi dibuat memiliki jumlah nilai yang seimbang berdasarkan kuantil distribusi normal standar (Dettmers dkk., 2023). QLoRA juga menerapkan Double Quantization, yaitu mengkuantisasi ulang konstanta kuantisasi itu sendiri untuk menghemat memori tambahan (rata-rata sekitar 0,37 bit per parameter), serta Paged Optimizer, yang memanfaatkan fitur *unified memory* NVIDIA untuk memindahkan *optimizer state* antara GPU dan CPU secara otomatis guna mengatasi lonjakan kebutuhan memori (*memory spike*) selama pelatihan. Selama proses *forward* dan *backward pass*, gradien tetap mengalir melalui bobot dasar yang terkuantisasi 4-bit menuju adapter LoRA yang dipertahankan pada presisi penuh (umumnya BFloat16).

Dengan kombinasi ketiga teknik tersebut, QLoRA memungkinkan *fine-tuning* model berskala puluhan miliar parameter pada satu unit GPU tunggal tanpa kehilangan kualitas yang signifikan dibandingkan *full fine-tuning* 16-bit (Dettmers dkk., 2023).

2.2.4 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) adalah pendekatan yang menggabungkan komponen *retriever* yang mencari dan mengambil dokumen atau potongan teks relevan dari suatu korpus eksternal dengan komponen *generator* berupa LLM yang menyusun jawaban akhir berdasarkan dokumen yang diambil tersebut (Lewis dkk., 2020). Pendekatan ini dikembangkan untuk mengatasi keterbatasan LLM yang hanya mengandalkan pengetahuan statis hasil pra-pelatihan, dengan memberikan akses terhadap informasi eksternal yang dapat diperbarui tanpa perlu melatih ulang model.

Proses RAG umumnya terbagi menjadi dua fase: fase *indexing* yang dilakukan secara *offline*, yaitu mengubah seluruh dokumen dalam korpus menjadi representasi vektor (*embedding*) dan menyimpannya dalam basis data vektor; serta fase *query-time* yang dilakukan secara *online* saat sistem menerima pertanyaan, yaitu mengubah pertanyaan menjadi vektor *query*, mengambil sejumlah k dokumen paling relevan (*top-k retrieval*), kemudian menyusun dokumen tersebut bersama pertanyaan ke dalam satu *prompt* yang diberikan kepada LLM.

Perlu ditegaskan bahwa penelitian ini mengadopsi pendekatan RAG in-context injection, yaitu konteks hasil pencarian disuntikkan langsung ke dalam *prompt* (terdiri atas instruksi sistem, konteks yang diambil, dan pertanyaan pengguna) sebagai input bagi LLM yang telah jadi (*off-the-shelf* atau hasil *fine-tuning*). Pendekatan ini berbeda dari arsitektur RAG orisinal yang diusulkan Lewis dkk. (2020), di mana komponen *retriever* dan *generator* dilatih bersama (*end-to-end*) sehingga *retriever* turut dioptimalkan melalui *backpropagation* dari *loss generator*.

Dalam penelitian ini, sistem RAG diterapkan di atas LLM terbaik hasil *fine-tuning* pada Skenario 1, menggunakan pendekatan *in-context injection* karena beberapa pertimbangan praktis: pendekatan ini tidak memerlukan pelatihan ulang terhadap komponen *retriever* maupun *generator*, bersifat modular sehingga komponen *retriever* dapat diganti atau dikombinasikan tanpa mengubah model bahasa, serta memiliki kebutuhan komputasi yang jauh lebih murah dibandingkan melatih arsitektur RAG end-to-end dari awal.

2.2.5 Dense Retrieval dan Sentence Embedding

Dense retrieval adalah pendekatan pencarian informasi yang merepresentasikan teks baik *query* maupun dokumen dalam korpus sebagai vektor berdimensi tetap (*dense embedding*) menggunakan model *encoder*, sehingga kemiripan makna antar teks dapat diukur melalui kedekatan vektor dalam ruang representasi tersebut. Ukuran kemiripan yang umum digunakan adalah *cosine similarity*:

$$cos(u, v) = \frac{u \cdot v}{||u|| \cdot ||v||}$$

di mana u dan v masing-masing adalah vektor *embedding* dari *query* dan dokumen, $u \cdot v$ adalah hasil kali titik (*dot product*) antar vektor, dan $||u||$, $||v||$ adalah norma Euclidean dari masing-masing vektor.

Syarat mendasar agar *dense retrieval* berfungsi dengan benar adalah *query* dan korpus harus di-*embed* menggunakan model *encoder* yang sama, sehingga keduanya berada pada ruang vektor (*vector space*) yang konsisten; penggunaan model *embedding* yang berbeda antara *query* dan korpus akan menyebabkan *mismatch* representasi dan menurunkan kualitas pencarian secara signifikan.

Penelitian ini mencoba dua model *dense embedding*, multilingual-E5-large-instruct, varian model E5 multibahasa yang menggunakan *instruction prefix* deskripsi tugas dalam bahasa alami yang disisipkan sebelum teks *query* untuk meningkatkan kualitas representasi sesuai konteks tugas pencarian (Wang dkk., 2024) dan BGE-M3, model *embedding* yang mendukung lebih dari 100 bahasa serta mampu memproses teks hingga 8.192 token, dan dirancang dengan kemampuan multi-fungsi yang mencakup *dense retrieval*, *sparse retrieval*, dan *multi-vector retrieval* sekaligus dalam satu model, tanpa memerlukan *instruction prefix* (Chen dkk., 2024).

Sebagai kontribusi novelti pada penelitian ini, selain strategi *indexing* standar yang meng-*embed* jawaban dokter sebagai basis pencarian, diuji pula strategi Q→Q retrieval, yaitu meng-*embed* pertanyaan atau keluhan pasien dari data historis dan mengembalikan jawaban dokter yang berkorespondensi dengannya ketika ditemukan kemiripan dengan pertanyaan pengguna saat ini. Strategi ini dirancang untuk mengurangi *semantic gap* antara bahasa awam yang digunakan pasien dalam mengungkapkan keluhan dan bahasa formal-medis yang digunakan dokter dalam menjawab, sebuah kesenjangan yang berpotensi menurunkan akurasi *retrieval* bila *query* pasien langsung dicocokkan dengan jawaban dokter. Strategi ini menjadi dasar perancangan Skenario 3.

2.2.6 Sparse Retrieval (BM25) dan Hybrid Search

BM25 (*Best Matching 25*) adalah algoritma pencarian leksikal (*sparse retrieval*) yang mengurutkan relevansi dokumen berdasarkan kemunculan term, menggabungkan *term frequency* (frekuensi kemunculan kata kunci dalam dokumen), *inverse document frequency* (bobot yang lebih tinggi untuk kata yang jarang muncul di seluruh korpus, dan karenanya lebih informatif), serta normalisasi terhadap panjang dokumen untuk mencegah dokumen panjang mendapat skor relevansi yang tidak proporsional (Robertson & Zaragoza, 2009).

Kelebihan utama BM25 terletak pada kemampuannya menangkap kecocokan istilah secara presisi termasuk nama obat, istilah medis spesifik, atau bahkan kesalahan ketik (*typo*) yang sama persis antara *query* dan dokumen karena pencariannya berbasis kecocokan kata literal. Namun, BM25 memiliki kelemahan mendasar: ia "buta" terhadap sinonim dan parafrase, sehingga *query* dan dokumen yang secara makna identik namun menggunakan kata berbeda tidak akan terdeteksi sebagai relevan.

Hybrid search menggabungkan skor dari *dense retrieval* (yang menangkap kemiripan makna/semantik) dengan skor BM25 (yang menangkap kecocokan leksikal), di mana kedua skor terlebih dahulu dinormalisasi menggunakan metode *min-max normalization* agar berada pada rentang yang sebanding, kemudian digabungkan melalui pembobotan linear:

$$score = w_{dense} \cdot norm(dense) + w_{bm25} \cdot norm(bm25)$$

Penelitian ini menetapkan bobot $w_{dense} = 0.6$ dan $w_{bm25} = 0.4$, memberikan penekanan lebih besar pada kemiripan semantik namun tetap mempertahankan kontribusi kecocokan leksikal.

Pendekatan *hybrid* dipilih dalam penelitian ini karena sifat saling melengkapi antara kedua metode: *dense retrieval* unggul dalam menangkap makna keluhan pasien yang diungkapkan dengan bahasa awam dan bervariasi, sementara BM25 unggul dalam menangkap istilah medis langka atau nama obat spesifik yang mungkin kurang terwakili dengan baik dalam ruang *embedding*. Kombinasi keduanya diharapkan menutup kekurangan masing-masing metode secara individual.

2.2.7 Model Pra-terlatih yang Digunakan

Pemilihan model dasar merupakan elemen sentral dalam rancangan eksperimen penelitian ini, karena seluruh Skenario 1 dirancang untuk membandingkan secara langsung tiga model dengan filosofi pra-pelatihan yang berbeda.

BioMistral-7B-DARE dibangun di atas basis Mistral-7B-Instruct-v0.1 dan dilanjutkan pra-pelatihannya (*continued pre-training*) pada korpus biomedis berskala besar yang bersumber dari PubMed Central Open Access, menjadikannya model bahasa biomedis sumber terbuka pertama yang dikembangkan dari basis Mistral (Labrak dkk., 2024). Untuk mempertahankan kemampuan mengikuti instruksi sekaligus memperkuat pengetahuan domain medis, BioMistral menerapkan teknik *model merging* DARE (*Drop And REscale*), yang menggabungkan bobot dari model hasil pra-pelatihan biomedis dengan bobot model instruct menggunakan metode konsensus tanda (*sign consensus*) untuk mencegah hilangnya informasi penting akibat interferensi parameter. BioMistral menunjukkan performa kuat pada berbagai *benchmark* medis berbahasa Inggris seperti MedQA dan PubMedQA, namun evaluasi pada paper aslinya turut melaporkan penurunan performa yang signifikan ketika model diuji pada bahasa selain Inggris temuan inilah yang menjadi dasar pengujian lebih lanjut terhadap kemampuan BioMistral dalam konteks bahasa Indonesia pada penelitian ini.

Qwen2.5-7B-Instruct merupakan bagian dari rangkaian model bahasa besar yang dikembangkan Alibaba, dilatih pada korpus pra-pelatihan berskala sangat besar mencapai sekitar 18 triliun token yang mencakup berbagai bahasa, termasuk bahasa-bahasa Asia, kemudian dilanjutkan dengan proses *instruction-tuning* melalui *supervised fine-tuning* berskala lebih dari satu juta sampel serta pembelajaran penguatan multi-tahap (*reinforcement learning*) mencakup DPO dan GRPO untuk meningkatkan keselarasan model terhadap preferensi manusia. Sebagai model dengan orientasi *language-first*, Qwen2.5 dirancang untuk

unggul dalam kemampuan mengikuti instruksi dan penalaran umum lintas bahasa, namun tidak secara khusus diadaptasi untuk domain medis.

Gemma-SEA-LION-v3-9B-IT dibangun di atas basis Gemma2-9B dan diadaptasi secara khusus oleh AI Singapore untuk bahasa-bahasa Asia Tenggara termasuk Indonesia, Jawa, dan Sunda melalui proses pelatihan bertahap yang mencakup tahap *instruction fine-tuning* berbahasa Inggris dan tahap *instruction fine-tuning* multibahasa untuk memperkuat kemampuan regional sekaligus mempertahankan kapabilitas penalaran umum (Ng dkk., 2025). Dari ketiga model yang dibandingkan, SEA-LION memiliki penguasaan bahasa daerah dan bahasa Indonesia yang paling mendalam, menjadikannya model dengan orientasi *regional-first*.

Tabel 2.2 Perbandingan antarmodel

Model	Base	Ukuran	Data/Strategi Pra-latih	Positioning
BioMistral-7B-DARE	Mistral-7B-Instruct-v0.1	7B	*Continued pre-training* pada korpus biomedis PubMed Central; *model merging* DARE dengan bobot instruct	*Domain-first* (medis, Inggris)
Qwen2.5-7B-Instruct	Qwen2.5 base	7B	Pra-pelatihan ~18T token multibahasa; *instruction-tuning* skala besar + RL (DPO, GRPO)	*Language-first* (multibahasa umum)
Gemma-SEA-LION-v3-9B-IT	Gemma2-9B	9B	Adaptasi regional Asia Tenggara; *instruction-tuning* dua tahap (Inggris → multibahasa SEA)	*Regional-first* (Indonesia & SEA)

Pemilihan ketiga model ini berdasarkan rancangan eksperimen yang disengaja untuk mencoba secara langsung tiga *postioning* yang berbeda, domain-first (BioMistral, kuat di pengetahuan medis namun lemah di bahasa non-Inggris), language-first (Qwen2.5, kuat lintas bahasa namun generik di domain medis), dan regional-first (SEA-LION, paling dalam penguasaan bahasa Indonesia namun tanpa spesialisasi medis eksplisit). Hipotesis inti yang diuji dalam Skenario 1 adalah bahwa untuk tugas *question answering* medis berbahasa Indonesia yang bersumber dari forum konsultasi awam, penguasaan bahasa target (baik melalui pendekatan *language-first* maupun *regional-first*) diduga lebih menentukan kualitas jawaban dibandingkan kedalaman pengetahuan domain medis yang terikat pada bahasa Inggris.

2.2.8 Metrik Evaluasi

Evaluasi kualitas jawaban yang dihasilkan sistem dilakukan menggunakan kombinasi metrik berbasis kemiripan permukaan (*lexical overlap*), metrik berbasis kemiripan semantik, metrik kesetiaan faktual, serta uji signifikansi statistik.

1. Token-F1
   Metrik ini menghitung *harmonic mean* antara *precision* dan *recall* berdasarkan irisan token antara jawaban prediksi dan jawaban referensi. Token-F1 mengukur sejauh mana kata-kata dalam jawaban prediksi bertumpang tindih dengan kata-kata pada jawaban referensi. Keterbatasannya metrik ini buta terhadap urutan kata dan makna dua jawaban dengan susunan kata acak namun token yang sama dapat memperoleh skor tinggi meski tidak koheren secara makna.

$$F1 = 2\frac{P \cdot R}{P+R}$$

2. BLEU (*Bilingual Evaluation Understudy*)
   BLEU mengukur presisi kecocokan *n-gram* antara teks yang dihasilkan dan referensi, dengan tambahan *brevity penalty* untuk menghukum keluaran yang terlalu pendek dibanding referensi (Papineni dkk., 2002). Metrik ini awalnya dirancang untuk evaluasi terjemahan mesin dan cenderung lemah ketika diterapkan pada tugas dengan jawaban *open-ended* seperti QA medis, di mana terdapat banyak cara valid untuk merumuskan jawaban yang benar secara semantik namun berbeda secara leksikal dari satu referensi.

$$BLEU = BP \cdot exp\left(\sum_{n=1}^{N} w_n log\, p_n\right)$$

   dengan p_n adalah presisi *n-gram* (proporsi *n-gram* pada teks prediksi yang juga muncul pada referensi, untuk $n = 1,\ldots, N$), w_n adalah bobot tiap orde *n-gram*, dan BP (*brevity penalty*) adalah faktor penalti yang mengecilkan skor apabila panjang teks prediksi c lebih pendek dari panjang referensi r.

$$\mathrm{BP} = \begin{cases} 1 & \text{jika } c > r \\ \exp(1 - r/c) & \text{jika } c \leq r \end{cases}$$

3. ROUGE-L
   ROUGE-L mengukur kecocokan berdasarkan *longest common subsequence* (LCS) antara teks prediksi dan referensi, sehingga turut mempertimbangkan urutan kata tanpa mensyaratkan kecocokan berurutan persis (Lin, 2004). Metrik ini mengindikasikan sejauh mana isi jawaban referensi tercakup dalam jawaban prediksi. Keterbatasannya: tetap berbasis kecocokan permukaan (leksikal) dan hanya dibandingkan terhadap satu referensi, sehingga tidak dapat menangkap variasi jawaban yang sah namun berbeda formulasi.

$$R_{lcs} = \frac{LCS(X,Y)}{m},\ P_{lcs} = \frac{LCS(X,Y)}{n},\ F_{lcs} = \frac{(1+\beta^2)R_{lcs}P_{lcs}}{R_{lcs}+\beta^2 P_{lcs}}$$

4. BERTScore
   BERTScore menghitung *cosine similarity* antar representasi *embedding* tiap token (alih-alih kecocokan kata persis) menggunakan model *encoder* berbasis Transformer dalam konteks multibahasa, umumnya menggunakan model xlm-roberta-large (Zhang dkk., 2020). Metrik ini mengukur kemiripan semantik antar token, sehingga lebih toleran terhadap parafrase dibanding metrik berbasis *n-gram*. Keterbatasannya:

kualitas skor sangat bergantung pada kualitas model *embedding* yang digunakan, dan skor kemiripan semantik yang tinggi tidak menjamin kebenaran faktual dari jawaban yang dihasilkan.

$$BERTScore = 2 \cdot \frac{P_{BERT} \cdot R_{BERT}}{P_{BERT} + R_{BERT}}$$

dengan P_{BERT}, R_{BERT} dihitung dari max_j

5. Semantic Similarity
   Metrik ini menghitung *cosine similarity* antara *embedding* tingkat kalimat (menggunakan model E5) dari keseluruhan jawaban prediksi terhadap jawaban referensi, mengukur kedekatan makna secara holistik alih-alih per token. Keterbatasannya, skor dapat tetap tinggi meskipun terdapat detail klinis krusial yang keliru (misalnya dosis atau nama obat yang salah), karena kesalahan pada detail kecil cenderung tidak banyak menggeser representasi makna kalimat secara keseluruhan.

$$SemanticSimilarity(y, \widehat{y}) = cos(E(y), E(\widehat{y})) = \frac{E(y) \cdot E(\widehat{y})}{||E(y)|| \cdot \left|\left|E(\widehat{y})\right|\right|}$$

6. NLI Faithfulness
   Metrik ini menggunakan model *Natural Language Inference* (NLI) multibahasa seperti mDeBERTa-xnli untuk memeriksa apakah jawaban yang dihasilkan ter-*entail* (didukung secara logis) oleh konteks atau jawaban referensi yang diberikan, sehingga berfungsi sebagai mekanisme deteksi halusinasi atau kontradiksi pada keluaran model. Metrik ini mengukur kesetiaan (*faithfulness*) jawaban terhadap sumber, bukan kemiripan permukaan. Keterbatasannya: akurasi deteksi sangat bergantung pada kualitas model NLI itu sendiri ketika diterapkan lintas bahasa, khususnya untuk bahasa Indonesia yang representasinya dalam data pelatihan model NLI multibahasa relatif lebih terbatas dibanding bahasa-bahasa berresource tinggi.

$$\text{Faithfulness}(\hat{y}, c) = \mathbb{1}\Big[\arg\max_{l \in \{e,n,k\}} P_{\text{NLI}}(l \mid c, \hat{y}) = e\Big]$$

7. Uji Signifikansi Wilcoxon Signed-Rank
   Pemilihan uji ini didasari dua karakteristik data hasil evaluasi yakni, pertama, data bersifat berpasangan (*paired*), karena setiap sampel pertanyaan dievaluasi pada model dan kondisi yang sama sehingga skor antar kondisi yang dibandingkan berasal dari unit observasi yang identik; kedua, distribusi selisih skor antar kondisi tidak dapat diasumsikan mengikuti distribusi normal, sehingga uji parametrik seperti *paired t-test* berisiko menghasilkan kesimpulan yang tidak valid. Wilcoxon Signed-Rank Test, sebagai uji non-parametrik yang bekerja berdasarkan peringkat selisih berpasangan, dipilih karena tidak mensyaratkan asumsi normalitas tersebut sekaligus tetap memanfaatkan struktur data berpasangan untuk meningkatkan daya uji (*power*) dibandingkan uji non-parametrik tidak berpasangan.

$$W = \sum_{i=1}^{n} \text{sgn}(d_i) \cdot R_i, \quad d_i = x_i - y_i$$

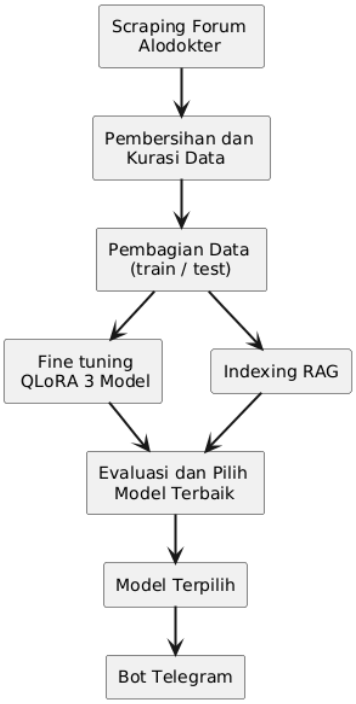
Perlu ditegaskan bahwa seluruh metrik evaluasi, baik yang berbasis kemiripan leksikal seperti Token F1, BLEU, dan ROUGE L maupun yang berbasis semantik seperti BERTScore, Semantic Similarity, dan NLI Faithfulness, pada dasarnya hanya mengukur kemiripan jawaban model terhadap satu jawaban dokter sebagai referensi. Metrik tersebut tidak secara langsung menilai kebenaran medis atau keamanan klinis. Karena itu, jawaban dengan skor tinggi belum tentu benar secara klinis, sedangkan jawaban dengan skor rendah masih mungkin benar jika dirumuskan secara berbeda. Keterbatasan ini diakui sebagai batasan evaluasi penelitian dan akan dibahas lebih lanjut pada Bab 4.

BAB 3 METODOLOGI

3.1 Perancangan Sistem

Penelitian ini membangun sistem tanya-jawab kesehatan berbahasa Indonesia yang menempuh dua jalur kerja yang saling melengkapi, yakni jalur pelatihan model dan jalur penambahan pengetahuan saat inferensi. Pada jalur pelatihan, tiga model bahasa besar dengan strategi pra-latih berbeda diadaptasi ke data forum Alodokter memakai QLoRA, lalu ketiga model tersebut digabung dengan Retrieval-Augmented Generation (RAG) untuk menguji apakah penyuntikan jawaban dokter terdahulu memperbaiki kualitas jawaban. Keseluruhan rancangan berangkat dari satu dugaan bahwa untuk pertanyaan medis berbahasa Indonesia dari forum awam, penguasaan bahasa lebih menentukan daripada pengetahuan domain medis berbahasa Inggris.

Keterkaitan kedua jalur tersebut secara menyeluruh ditunjukkan pada di bawah ini.



Gambar 3.1 Diagram alur sistem

Sistem diuji melalui tiga skenario yang dirancang untuk menjawab tiap rumusan masalah secara terpisah sebelum hasilnya dibahas pada Bab 4.

1. **Efektivitas Fine-tuning QLoRA (base vs fine-tuned)**
   Skenario ini membandingkan tiap model pada kondisi *base* (tanpa adaptasi) terhadap kondisi *fine-tuned*. Ketiga model - BioMistral-7B-DARE, Qwen2.5-7B-Instruct, dan Gemma-SEA-LION-v3-9B-IT - mewakili tiga strategi pra-latih (berorientasi domain, berorientasi bahasa, dan berorientasi kawasan), sehingga perbandingan ini sekaligus menjawab model mana yang paling sesuai untuk tugas tanya-jawab medis berbahasa Indonesia.

2. **Kontribusi RAG (fine-tuned vs fine-tuned + RAG)**
   Skenario ini membandingkan ketiga model hasil skenario 1 pada kondisi *fine-tuned* terhadap *fine-tuned + RAG*. Perbandingan dilakukan berpasangan pada pertanyaan yang sama agar selisihnya murni berasal dari penambahan konteks.

3. **Kualitas Retrieval (perbandingan metode retrieval)**
   Skenario ini menguji kualitas komponen retrieval secara terpisah dari proses generasi. Pengujian dilakukan menggunakan metrik peringkat standar, yaitu Recall@3, Recall@5, nDCG@5, dan MRR, agar dapat diketahui sejauh mana kualitas pencarian memengaruhi kualitas keseluruhan sistem. Selain itu, dilakukan ablasi komponen retrieval serta variasi bobot hybrid untuk menentukan konfigurasi optimal antara dense retrieval dan BM25.

3.2 Implementasi Sistem

Implementasi diuraikan menurut urutan alir pada Gambar 3.1, dari pengumpulan data hingga penyajian jawaban, dengan nilai hyperparameter ditulis lengkap pada tiap tahap agar percobaan dapat diulang.

3.2.1 Pengumpulan Data

Data berasal dari forum kesehatan Alodokter, tempat pengguna awam bertanya dan dokter menjawab. Dari tiap topik diambil empat jenis informasi, yaitu kategori topik (*poli_tujuan*), tautan sumber (*url*), keluhan pasien (*keluhan*), dan jawaban dokter (*jawaban*). Keluhan menjadi masukan model dan kueri retrieval, sedangkan jawaban dokter menjadi target pelatihan sekaligus sumber pengetahuan RAG.

Pengambilan data dilakukan dengan teknik web scraping menggunakan bahasa Python serta pustaka requests dan BeautifulSoup untuk mengakses halaman forum dan mengambil keempat field yang dibutuhkan pada setiap laman topik. Karena Alodokter menampilkan balasan anggota dan dokter dengan penanda yang serupa, hanya balasan yang berperan sebagai dokter yang diambil sebagai jawaban agar respons dari pengguna non dokter tidak tercampur.

3.2.2 Pembersihan dan Kurasi Data

Jawaban dokter mentah memuat sapaan, identitas dokter, ajakan menutup percakapan, dan rujukan merek "Alodokter" yang tidak relevan secara medis. Pembersihan berjalan bertahap (*waterfall*) dengan gerbang mutu (*quality gate*) di akhir tiap tahap. Pemecahan ke

beberapa tahap, bukan satu fungsi gabungan, membuat tiap kesalahan mudah terdeteksi dan tiap penghapusan dapat ditelusuri.

Keenam tahap berjalan berurutan, mencakup pembakuan teks (memperbaiki *mojibake*, membuang karakter kendali, URL, dan emoji), penggantian merek "Alodokter" menjadi "Medi" pada jawaban sementara keluhan dibiarkan alami, pembuangan bagian pembuka (salam, nama, ucapan terima kasih, perkenalan dokter) dan tanda tangan dengan penutup hangat seperti "semoga membantu" tetap dipertahankan, normalisasi kata ganti orang pertama ke persona "Medi", pembuangan baris kosong dan duplikat persis, serta pembersihan lanjutan.



Sepanjang proses, nama obat dan penyakit dijaga agar tidak terhapus. Penghapusan nama hanya berlaku bila token menempel pada salam atau penanda "dr." dan tidak ada di daftar istilah obat/penyakit. Nama ambigu masuk file tinjauan manual lebih dulu, tidak langsung dibuang.

3.2.3 Pembagian dan Format Data Latih

Sebelum *training*, data dipisah menjadi *training set* dan *test set* untuk mencegah kebocoran. *Test set* berisi 866 pasangan, diambil acak terstratifikasi per kategori topik (*poli_tujuan*) dengan seed 42 agar komposisinya mewakili *corpus*. Tiap baris test set menyimpan *corpus_id* penunjuk barisnya sendiri, dipakai untuk mengecualikan jawaban asli saat evaluasi RAG. Sisanya, 58.074 pasangan, menjadi *training set*.

Tiap pasangan diformat ke struktur percakapan tiga peran, yaitu *system*, *user*, dan *assistant*. Pesan *system* memuat persona "Medi" sebagai asisten kesehatan yang menjawab empatik dan menyarankan konsultasi medis bila perlu. Keluhan pasien menjadi pesan *user*, jawaban dokter menjadi pesan *assistant*. Format ini seragam untuk ketiga model agar perbandingan adil. Dari *training set* diambil acak 15.000 pasangan sebagai data pelatihan efektif, menekan waktu dan biaya GPU.

3.2.4 Fine-tuning dengan QLoRA

Ketiga model diadaptasi memakai QLoRA dengan konfigurasi seragam, sehingga perbedaan hasil mencerminkan modelnya, bukan setelan. Bobot dasar dikuantisasi 4-bit NF4 dengan kuantisasi ganda (*double quantization*) dan komputasi bf16, sehingga model 7-9 miliar parameter muat pada satu GPU A100 40 GB. Adaptor LoRA dipasang pada seluruh linear layer (*all-linear*) dengan rank 16, alpha 32, dan dropout 0,05. Rank 16 menyeimbangkan kapasitas adaptasi dan jumlah parameter terlatih, sedangkan alpha 32 mengikuti praktik umum LoRA (skala dua kali rank).

Pelatihan berjalan satu epoch, dengan batch per perangkat 4 dan akumulasi gradien 8 langkah (batch efektif 32). Learning rate 2×10^{-4} memakai cosine scheduler dengan warmup 3%, dioptimasi paged AdamW 8-bit. Panjang urutan dibatasi 1.536 token dan *gradient checkpointing* aktif untuk menghemat memori. Seed 42 dipakai di semua proses. SEA-LION menuntut dua penyesuaian khusus, yaitu mode atensi *eager* dan token autentikasi karena

modelnya gated. Seluruh pelatihan berjalan pada GPU NVIDIA A100 40 GB lewat layanan *serverless* Modal.

Komponen	Nilai
Quantization	4-bit NF4, double quant, komputasi bf16
LoRA rank / alpha / dropout	16 / 32 / 0,05
Target modules	all-linear
Epochs	1
Per-device batch size × gradient accumulation steps	4 × 8 (efektif 32)
Learning rate / scheduler	2×10^{-4} / cosine, warmup 3%
Optimizer	paged AdamW 8-bit
Max sequence length	1.536 token

3.2.5 Pembangunan Index RAG

Index dibangun dengan corpus 58.940 jawaban dokter. Tiap jawaban diubah menjadi vektor padat dengan multilingual-e5-large-instruct (peringkat teratas bahasa Indonesia pada tolok ukur SEA-BED). Jawaban yang melewati embedding window dipecah menjadi chunk 250 token dengan overlap 30 token, selebihnya dipakai utuh. Corpus yang sama diindeks secara leksikal dengan BM25, lalu kedua jalur digabung sebagai pencarian *hybrid* agar vektor padat menangkap makna semantik sementara BM25 menangkap istilah medis spesifik. Vektor dinormalkan dan disimpan sebagai matriks numpy untuk pencarian eksak, memadai untuk ratusan ribu vektor tanpa indeks aproksimat.

3.2.6 Retrieval dan Penyusunan Prompt

Saat inferensi, keluhan pengguna diubah menjadi vektor dengan model embedding yang sama, disertai instruction prefix agar ruang vektor kueri sepadan dengan dokumen. Dense score dan BM25 score dihitung atas kumpulan kandidat, dinormalkan min-max, lalu digabung dengan weight 0,6 untuk dense dan 0,4 untuk BM25, condong ke dense karena kesepadanan makna lebih menentukan untuk bahasa awam pasien. Tiga dokumen teratas menjadi konteks. Saat evaluasi, jawaban asli milik pertanyaan dikecualikan lewat *corpus_id* agar model tidak menyalin acuan. Konteks lalu disusun ke prompt bersama pesan *system* yang menyuruh model mensintesis, bukan menyalin verbatim, dan pesan *user* berisi referensi diikuti pertanyaan. Instruksi sintesis ini ditambahkan setelah RAG naif terbukti mendorong penyalinan langsung.

3.2.7 Evaluasi

Evaluasi menilai tiga kondisi tiap model, yaitu *base*, *fine-tuned* (ft), dan *fine-tuned* + *RAG* (ft_rag). Prompt ketiga kondisi mereplikasi format pelatihan dan dekoding memakai *greedy* deterministik. Panjang jawaban dibatasi 420 token baru dengan minimum 40, sebab batas lebih kecil terbukti memotong mayoritas jawaban. Pengulangan ditekan dengan penalti 1,2 dan pemblokiran n-gram ukuran 3.

Mutu jawaban diukur terhadap jawaban dokter asli memakai enam metrik yang saling melengkapi. Token-F1 dan ROUGE-L mengukur overlap kata, BLEU mengukur presisi n-gram, BERTScore (xlm-roberta-large) dan kemiripan semantik berbasis embedding e5 mengukur kedekatan makna, serta NLI *faithfulness* (mDeBERTa-xnli) khusus kondisi RAG mengukur apakah jawaban didukung oleh konteks terambil. Signifikansi selisih antarkondisi diuji dengan Wilcoxon *signed-rank* berpasangan pada skor per-pertanyaan. Uji ini dipilih karena data berpasangan (model dan pertanyaan sama) dan distribusi selisihnya tidak diasumsikan normal.

Sebagai batasan, keenam metrik mengukur kemiripan permukaan atau makna terhadap satu jawaban acuan, bukan kebenaran atau keamanan klinis. Batasan ini dibahas lebih lanjut di Bab 4.

3.2.8 Deployment

Model terbaik dan pipeline RAG dipasang sebagai bot Telegram untuk demonstrasi langsung. Bot memakai mekanisme *long-polling*. Setiap pesan masuk diproses berurutan, dari pengambilan konteks lewat retrieval, penyusunan prompt, pemanggilan model, hingga pengiriman jawaban dengan disklaimer bahwa informasi bersifat edukatif dan bukan pengganti konsultasi medis

BAB 4 HASIL DAN PEMBAHASAN

4.1 Konfigurasi Lingkungan Penelitian

Seluruh percobaan dijalankan pada lingkungan yang seragam agar hasil antarmodel dan antarkondisi dapat dibandingkan secara adil. Pelatihan QLoRA ketiga model berjalan pada GPU NVIDIA A100 40 GB lewat layanan serverless Modal, sedangkan pembangunan index RAG dan evaluasi generasi dijalankan pada GPU NVIDIA 4050 6GB. Tumpukan perangkat lunak utama meliputi PyTorch sebagai kerangka komputasi, Hugging Face Transformers untuk pemuatan model, PEFT untuk adaptor LoRA, dan bitsandbytes untuk kuantisasi 4-bit.

Tabel 4.1 Rangkuman spesifikasi lengkap lingkungan penelitian.

Komponen	Nilai
Lingkungan pelatihan	NVIDIA A100 40 GB (Modal serverless)
Lingkungan evaluasi	NVIDIA A100 40 GB (Modal serverless)
Lingkungan indexing	GPU NVIDIA 4050 6GB
Python	3.11
PyTorch	2.10.0+cu128
Transformers	5.0.0
PEFT	0.19.1
bitsandbytes	0.49.2

4.2 Hasil Penelitian

Hasil penelitian disusun berdasarkan tiga skenario pengujian yang telah dirancang pada Bab 3. Setiap skenario merepresentasikan satu rumusan masalah, dimulai dari evaluasi efektivitas fine-tuning, dilanjutkan dengan analisis kontribusi RAG, dan diakhiri dengan penilaian kualitas komponen retrieval.

4.2.1 Skenario 1 - Efektivitas Fine-tuning QLoRA

Skenario pertama bertujuan untuk membandingkan performa setiap model pada kondisi base dan fine-tuned, sekaligus membandingkan ketiga model secara keseluruhan.

Tabel 4.2 menyajikan enam metrik evaluasi untuk sembilan kombinasi model dan kondisi, sedangkan Tabel 4.3 menampilkan hasil uji signifikansi menggunakan Wilcoxon signed-rank terhadap selisih performa antara kondisi base dan fine-tuned.

Tabel 4.2 Skor metrik base vs fine-tuned (n=100).

Model	Kondisi	F1	BLEU	ROUGE-L	BERTScore	sem-sim
BioMistral	base	0,1384	0,0082	0,0976	0,8405	0,8950
	fine-tuned	0,2150	0,0229	0,1474	0,8555	0,9159
Qwen2.5	base	0,2499	0,0215	0,1376	0,8593	0,9320
	fine-tuned	0,2625	0,0316	0,1592	0,8623	0,9266
SEA-LION	base	0,2708	0,0252	0,1517	0,8599	0,9336
	fine-tuned	0,2556	0,0407	0,1653	0,8582	0,9333

Fine-tuning memberikan peningkatan paling besar pada BioMistral, yaitu model dengan performa awal terendah. Nilai Token-F1 meningkat dari 0,1384 menjadi 0,2150, sementara ROUGE-L naik dari 0,0976 menjadi 0,1474, yang merupakan kenaikan terbesar dibandingkan model lainnya.

Pola ini dapat dipahami karena BioMistral berorientasi pada domain medis berbahasa Inggris, sehingga memperoleh banyak peningkatan dalam hal gaya jawaban dan penggunaan bahasa Indonesia dari data Alodokter.

Sementara itu, Qwen2.5 menunjukkan peningkatan yang lebih kecil namun konsisten pada seluruh metrik overlap. Berbeda dengan keduanya, SEA-LION menunjukkan hasil yang bervariasi: metrik BLEU dan ROUGE-L meningkat, tetapi Token-F1 dan kemiripan semantik sedikit menurun. Hal ini mengindikasikan bahwa SEA-LION sudah memiliki performa yang cukup kuat sejak kondisi awal, sehingga fine-tuning tidak memberikan peningkatan yang signifikan dan pada beberapa aspek justru menyebabkan pergeseran dari acuan.

*Tabel 4.3 Uji signifikansi base → fine-tuned (Wilcoxon signed-rank, p<0,05 = *).*

Model	Metrik	mean Δ	p-value	sig
BioMistral	F1	+0,0765	0,0000	*
	BLEU	+0,0146	0,0000	*
	ROUGE-L	+0,0498	0,0000	*
	BERTScore	+0,0150	0,0000	*

	sem-sim	+0,0208	0,0000	*
Qwen2.5	F1	+0,0126	0,0128	*
	BLEU	+0,0101	0,0005	*
	ROUGE-L	+0,0217	0,0001	*
	BERTScore	+0,0030	0,0019	*
	BERTScore	+0,0030	0,0019	*
SEA-LION	F1	-0,0153	0,1701	
	BLEU	+0,0155	0,0032	*
	ROUGE-L	+0,0135	0,1402	
	BERTScore	-0,0017	0,9589	
	sem-sim	-0,0004	0,5729	

Pada model BioMistral, seluruh perbedaan yang dihasilkan bersifat signifikan dengan nilai p yang mendekati nol. Hal ini menunjukkan bahwa fine-tuning menggunakan QLoRA benar-benar meningkatkan performa model domain-first tersebut, bukan sekadar akibat fluktuasi. Pada model Qwen2.5, peningkatan signifikan terlihat pada lima metrik overlap. Namun, pada metrik kemiripan semantik terdapat penurunan kecil yang tetap signifikan secara statistik.Sementara itu, model SEA-LION hanya menunjukkan peningkatan signifikan pada metrik BLEU, sedangkan perubahan pada metrik lainnya tidak signifikan. Temuan ini mengindikasikan bahwa model tersebut telah mendekati batas optimal performanya untuk tugas ini, bahkan sejak kondisi awal (base). Pada kondisi terbaiknya, yaitu setelah fine-tuning, model SEA-LION unggul pada sebagian besar metrik dan dipilih sebagai model terbaik secara keseluruhan untuk tahap RAG.

Lebih lanjut, hasil ini menunjukkan bahwa model berbasis *language-first* dan regional, yaitu Qwen2.5 dan SEA-LION, secara konsisten mengungguli model *domain-first* seperti BioMistral pada hampir seluruh metrik evaluasi. Temuan ini mendukung hipotesis bahwa dalam konteks QA medis berbahasa Indonesia, khususnya dari forum awam, kemampuan penguasaan bahasa memiliki peran yang lebih penting dibandingkan pengetahuan domain medis yang berbasis bahasa Inggris.

4.2.2 Skenario 2 - Kontribusi RAG

Skenario kedua menambahkan komponen retrieval pada semua model, kemudian membandingkan kondisi fine-tuned dengan fine-tuned + RAG secara berpasangan pada pertanyaan yang sama.

Tabel 4.4 menyajikan hasil skor evaluasi, sedangkan Tabel 4.5 menampilkan hasil uji signifikansi. Perlu dicatat bahwa kolom *faithfulness* hanya tersedia pada kondisi RAG, karena metrik ini digunakan untuk mengukur sejauh mana jawaban didukung oleh konteks yang diambil melalui proses retrieval.

Tabel 4.4 Skor fine-tuned vs fine-tuned + rag

Model	**Kondisi**	**F1**	**BLEU**	**ROGUE-L**	**BERTScore**	**Sem-Sim**	**Faithfullness**
BioMistral	fine-tuned	0,2150	0,0229	0,1474	0,8555	0,9159	-
	finetuned_rag	0,2134	0,0188	0,1408	0,8555	0,9149	**0,4494**
Qwen 2.5	fine-tuned	0,2625	0,0316	0,1592	**0,8623**	0,9266	-
	fine-tuned_rag	0,2320	0,0255	0,1447	0,8541	0,9175	0,4143
SEA-LION	fine-tuned	0,2556	0,0407	0,1653	0,8582	0,9333	-
	fine-tuned_rag	**0,2737**	**0,0422**	**0,1709**	0,8591	**0,9325**	0,3641

*Tabel 4.5 Uji signifikansi fine-tuned → fine-tuned + rag (Wilcoxon, p<0,05 = *)*

Model	Metrik	mean Δ	p-value	sig
BioMistral	F1	-0,0016	0,7431	
	BLEU	-0,0040	0,4034	
	ROUGE-L	-0,0066	0,1766	
	BERTScore	+0,0000	0,8906	
	sem-sim	-0,0009	0,7362	
Qwen2.5	F1	-0,0305	0,0019	*
	BLEU	-0,0061	0,0586	
	ROUGE-L	-0,0146	0,0142	*
	BERTScore	-0,0081	0,0031	*
	BERTScore	-0,0091	0,0011	*
SEA-LION	F1	+0,0181	0,3055	

	BLEU	0,0015	0,0032	
	ROUGE-L	+0,0057	0,4724	
	BERTScore	+0,0009	0,9315	
	sem-sim	-0,0008	0,5230	

Pada model SEA-LION sebagai model terpilih, penambahan RAG cenderung meningkatkan hampir seluruh metrik, kecuali kemiripan semantik yang mengalami penurunan sangat kecil. Namun, tidak ada perbedaan tersebut yang signifikan secara statistik. Hal ini menunjukkan bahwa pada model terbaik, RAG bersifat netral, yaitu tidak menurunkan kualitas, tetapi juga belum mampu meningkatkan performa secara meyakinkan.

Pola yang berbeda terlihat pada Qwen2.5, di mana penambahan RAG justru menurunkan sebagian besar metrik secara signifikan. Sementara itu, pada BioMistral, seluruh perubahan yang terjadi relatif kecil dan tidak signifikan.

Nilai *faithfulness* berada pada kisaran 0,36-0,45, yang menunjukkan bahwa kurang dari separuh isi jawaban benar-benar didukung oleh konteks yang diambil. Temuan ini sejalan dengan penelitian sebelumnya (Xiong dkk., 2024) yang menyatakan bahwa RAG tidak selalu meningkatkan kualitas secara otomatis, melainkan sangat bergantung pada kualitas proses retrieval. Oleh karena itu, hasil ini menjadi temuan penting yang dibahas lebih lanjut pada Subbab 4.3.

4.2.3 Skenario 3 - Kualitas Retrieval

Skenario ketiga berfokus pada evaluasi kualitas komponen retrieval secara terpisah dari proses generasi. Pengujian dilakukan menggunakan 866 pertanyaan pada data uji sebagai kueri, dengan jawaban dokter yang berpasangan sebagai acuan (*gold standard*).

Karena setiap kueri hanya memiliki satu jawaban acuan, metrik recall@k pada konteks ini ekuivalen dengan hit-rate@k.

Tabel 4.6 Perbandingan performa retrieval (top-k).

k	recall	precision	nDCG
1	0,4157	0,4157	0,4157
3	0,5751	0,1917	0,5087
5	0,6570	0,1314	0,5425
10	0,7344	0,0734	0,5674

Nilai Mean Reciprocal Rank (MRR) yang diperoleh adalah sebesar 0,5148. Nilai presisi cenderung menurun seiring bertambahnya nilai k, karena setiap kueri hanya memiliki satu

jawaban acuan, sehingga batas maksimum presisi adalah 1/k. Oleh karena itu, metrik yang lebih informatif dalam konteks ini adalah recall, nDCG, dan MRR.

Untuk menganalisis kontribusi masing-masing komponen retrieval, dilakukan studi ablasi dengan membandingkan tiga pendekatan, yaitu dense retrieval, BM25, dan kombinasi keduanya (hybrid). Hasil perbandingan tersebut disajikan pada Tabel 4.7.

Tabel 4.7 Ablasi komponen retrieval.

konfigurasi	**recall@1**	**recall@3**	**recall@5**	**nDCG@5**	**MRR**
dense saja	0,4065	0,5566	0,6316	0,5243	0,5015
BM25 saja	0,1316	0,2125	0,2714	0,2031	0,1887
hybrid 0,6/0,4	0,4157	0,5751	0,6570	0,5425	10

BM25 secara tunggal menunjukkan performa yang relatif rendah (recall@3 sebesar 0,21), kemungkinan karena pertanyaan pasien cenderung menggunakan parafrase sehingga tidak selalu cocok dengan kata kunci secara langsung.

Sebaliknya, pendekatan dense retrieval memberikan kontribusi utama dengan recall@3 sebesar 0,56. Ketika dikombinasikan dalam skema hybrid, performanya meningkat dan secara konsisten mengungguli dense retrieval pada seluruh metrik, yang menunjukkan bahwa kedua pendekatan tersebut saling melengkapi.

Analisis variasi bobot menunjukkan pola kurva cekung dengan nilai optimal pada dense_weight sebesar 0,6 (Tabel 4.8). Hal ini mengindikasikan bahwa konfigurasi yang digunakan merupakan hasil optimasi empiris, bukan sekadar penentuan secara arbitrer.

Tabel 4.8 Variasi bobot hybrid.

dense_weight	**recall@3**	**recall@5**	**nDCG@5**	**MRR**
0,0	0,2125	0,2714	0,2031	0,1887
0,1	0,2933	0,3545	0,2707	0,2548
0,2	0,3891	0,4654	0,3586	0,3332
0,3	0,4746	0,5647	0,4485	0,4197
0,4	0,5370	0,6212	0,5079	0,4796

0,5	0,5693	0,6467	0,5373	0,5115
0,6	**0,5751**	**0,6570**	**0,5425**	**0,5148**
0,7	0,5739	0,6559	0,5415	0,5142
0,8	0,5693	0,6443	0,5351	0,5109
0,9	0,5612	0,6432	0,5316	0,5065
1,0	0,5566	0,6316	0,5243	0,5015

4.2.4 Contoh Kualitatif

Untuk melengkapi angka, Tabel 4.9 menyajikan satu pertanyaan beserta jawaban keempat sumber agar perbedaan kualitas tampak nyata.

Tabel 4.9 Perbandingan hasil kualitatif jawaban.

Sumber	Jawaban
Keluhan pasien	"Malam dok, mau tanya obat Cefadroxil diminum sesudah makan atau sebelum dok? Makasih dok."
base	"Salam, dok! Obat Cefadroxil dapat dimana-mana diantarkan, sebelum atau sesudah makan. Namun, umumnya obat ini dapat dimana-mana diantarkan sebelum makan untuk mengurangi risiko terjadinya diperlukan untuk mengurangi risiko terjadinya diperlukan untuk mengurangi risiko terjadinya diperlukan untuk mengurangi risiko terjadinya ..." *(terjebak pengulangan hingga batas token)*
fine-tuned	"Cefadroxil adalah obat golongan antibiotik yang digunakan untuk mengatasi infeksi bakteri. Obat ini bekerja dengan cara menghambat pembentukan sel-sel bakteri .... Obat ini dapat dikonsumsi sebelum makan atau sesudah makan. Namun, sebaiknya Anda konsultasikan dengan dokter yang meresepkan obat ini pada Anda .... Semoga informasi ini dapat membantu."
fine-tuned + RAG	"Cefadroxil merupakan obat antibiotik yang digunakan untuk mengatasi infeksi bakteri. Obat ini harus dikonsumsi dengan anjuran dokter dan harus dengan resep dokter; jika mengonsumsi antibiotik sembarangan bisa menimbulkan risiko resisten terhadap antibiotik jenis tersebut .... Konsumsi antibiotik sebaiknya teratur setiap hari dan dihabiskan sesuai anjuran dokter walau sudah merasa sembuh ...."
Jawaban dokter asli	"Cefadroxil merupakan antibiotik spektrum luas yang bisa digunakan untuk mengobati infeksi yang disebabkan oleh berbagai jenis bakteri. Sebaiknya Anda mengonsumsi cefadroxil sesuai dosis dan aturan yang diberikan dokter. Sebaiknya cefadroxil dikonsumsi sesudah makan, mengingat efek sampingnya yang dapat menyebabkan mual .... Semoga membantu."

Tabel 4.9 ini memperlihatkan progres kualitas antarkondisi. Pada kondisi base, model terjebak pengulangan dan gagal menjawab pertanyaan. Setelah fine-tuning, jawaban menjadi koheren dan menyerupai gaya jawaban dokter, meski belum menegaskan aturan minum

sesudah makan seperti acuan. Penambahan RAG memasukkan detail dari konteks terambil, yaitu pentingnya resep dokter dan risiko resistensi antibiotik, walau tetap belum menjawab langsung pertanyaan waktu minum obat. Pola ini sejalan dengan temuan kuantitatif: fine-tuning memberi lonjakan kualitas terbesar, sedangkan RAG menambah konteks tanpa selalu menaikkan kesesuaian dengan jawaban acuan.

4.3 Pembahasan

Domain-first kalah dari language-first. Hasil Skenario 1 menunjukkan BioMistral, satu-satunya model domain-first, berangkat dari titik terendah dan walau naik paling banyak setelah fine-tuning tetap tidak menyusul Qwen2.5 maupun SEA-LION. Penjelasannya, keunggulan BioMistral terletak pada pengetahuan biomedis berbahasa Inggris hasil pra-latih di PubMed, sedangkan tugas ini menuntut pemahaman keluhan awam berbahasa Indonesia dan perangkaian jawaban yang luwes dalam bahasa itu. Pengetahuan domain Inggris tidak otomatis berpindah lintas bahasa, sementara penguasaan bahasa yang sudah dimiliki Qwen2.5 (multilingual) dan SEA-LION (dikhususkan Asia Tenggara) langsung terpakai. Untuk QA forum kesehatan Indonesia, modal bahasa lebih menentukan daripada modal domain medis berbahasa asing.

Mengapa RAG netral, bukan naik. Tiga sebab saling menguatkan. Pertama, mutu retrieval terbatas: recall@3 sekitar 0,58 dan faithfulness 0,36-0,45, sehingga konteks yang diambil sering relevan secara topik tetapi tidak persis pada aspek yang ditanya, dan model tidak selalu mendapat bahan yang menambah nilai. Kedua, corpus Alodokter sangat duplikatif: keluhan umum seperti "sakit kepala sebelah" muncul ratusan kali dengan jawaban dokter berbeda yang sama-sama valid, sehingga jawaban berpasangan yang persis sering tidak masuk top-3, dan metrik own-answer recall menjadi proksi yang pesimistis. Ketiga, RAG naif sempat mendorong model menyalin konteks verbatim sehingga butuh instruksi sintesis pada prompt; setelah perbaikan itu, RAG berhenti merusak tetapi belum cukup untuk menaikkan skor overlap terhadap satu jawaban acuan. Pada Qwen2.5 efek negatif RAG bahkan signifikan, menandakan model yang sudah kuat dapat terganggu oleh konteks yang tidak presisi. Temuan netral ini bukan kegagalan eksperimen melainkan hasil yang jujur dan sejalan dengan Xiong dkk. (2024).

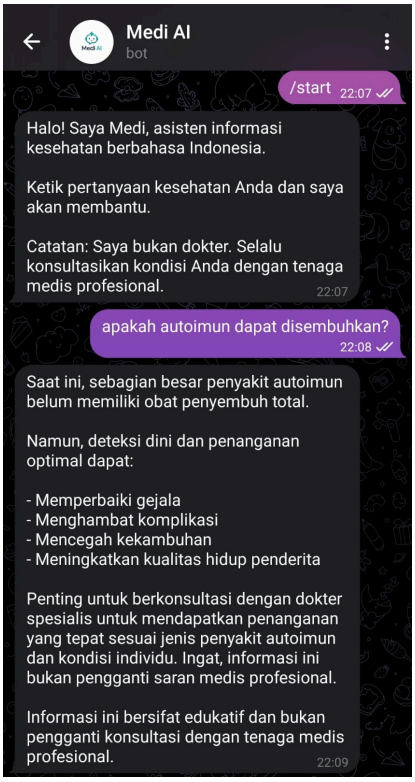
Keterbatasan metrik. Keenam metrik mengukur kemiripan permukaan (Token-F1, BLEU, ROUGE-L) atau makna (BERTScore, sem-sim, faithfulness) terhadap satu jawaban dokter acuan, bukan kebenaran atau keamanan klinis. Sebuah jawaban bisa benar dan aman secara medis namun berbeda kata dari acuan sehingga skornya rendah, atau sebaliknya mirip permukaan namun salah detail klinis. Karena banyak jawaban benar mungkin untuk satu keluhan, metrik berbasis acuan tunggal ini secara sistematis meremehkan kualitas, khususnya untuk kontribusi RAG. Keterbatasan ini diakui terbuka dan menjadi dasar saran perbaikan di Bab 5.

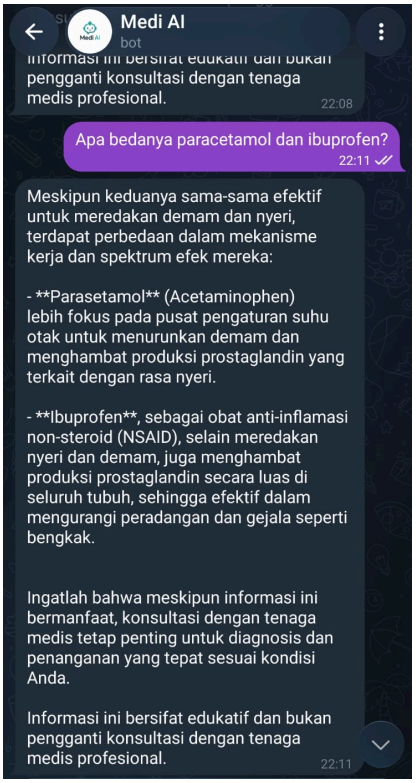
4.4 Deployment

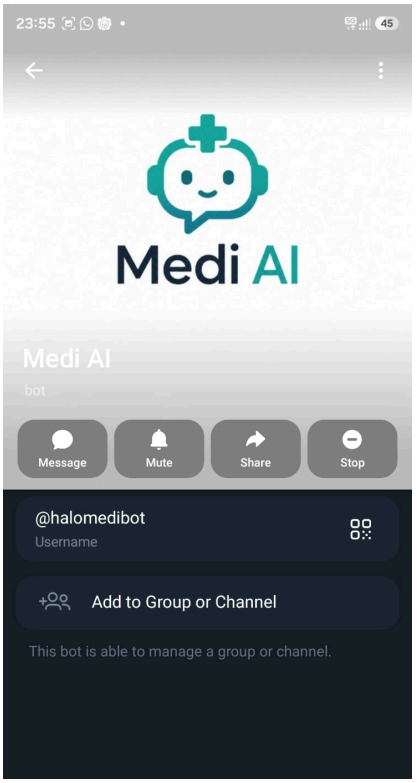
Sistem akhir berupa model terpilih yang diintegrasikan dengan pipeline RAG, kemudian diimplementasikan dalam bentuk bot Telegram sebagai media demonstrasi. Bot ini menerima keluhan dari pengguna, mengambil konteks melalui mekanisme retrieval hybrid, menyusun prompt, memanggil model, dan menghasilkan jawaban. Setiap respons yang

diberikan dilengkapi dengan *disclaimer* bahwa informasi yang disampaikan bersifat edukatif dan tidak menggantikan konsultasi medis profesional.

Gambar 4.1 Tampilan bot Medi AI pada platform Telegram







BAB 5 KESIMPULAN

Kesimpulan

Penelitian ini mengevaluasi dan membandingkan tiga Large Language Model (LLM), yaitu BioMistral-7B, Qwen2.5-7B-Instruct, dan Gemma-SEA-LION-9B-IT, yang di-fine-tune dengan QLoRA untuk tugas Medical Question Answering berbahasa Indonesia, lalu menerapkan RAG pada ketiga model. Dari hasil eksperimen, diperoleh beberapa poin utama sebagai berikut:

1. Efektivitas Fine-tuning QLoRA
   Fine-tuning QLoRA meningkatkan kualitas jawaban ketiga model, dengan peningkatan terbesar pada BioMistral yang seluruh metriknya naik signifikan (Token-F1 +0,0765, $p<0,001$). SEA-LION yang sudah kuat sejak kondisi base hanya naik signifikan pada BLEU.
2. Perbandingan Tiga Model
   Qwen2.5 dan SEA-LION (pendekatan language-first) mengungguli BioMistral (domain-first) pada hampir seluruh metrik. SEA-LION menjadi model terbaik dan dipilih untuk tahap RAG. Hasil ini menunjukkan kemampuan bahasa lebih menentukan daripada pengetahuan domain medis berbahasa Inggris.
3. Kontribusi RAG
   RAG bersifat netral pada model terpilih, yaitu tidak menaikkan maupun menurunkan kualitas secara signifikan. RAG tanpa instruksi sintesis justru menurunkan seluruh metrik karena model menyalin konteks, sehingga formulasi prompt menentukan keberhasilan RAG.

Sistem akhir berupa model terpilih dengan pipeline RAG telah di-deploy sebagai bot Telegram, sehingga informasi kesehatan awal dapat diakses masyarakat luas.

Saran

Kualitas retrieval (recall@3 0,5751) menjadi penghambat utama kontribusi RAG, sehingga penelitian selanjutnya disarankan menambahkan komponen *reranker* atau strategi *indexing Question-to-Question* yang pada eksperimen ini mencapai recall@1 0,9988. Selain itu, evaluasi sebaiknya melibatkan penilaian kebenaran dan keamanan klinis oleh ahli medis, bukan hanya kemiripan dengan satu jawaban acuan.

DAFTAR PUSTAKA

Hanami, R. N., Mahendra, R., & Wicaksono, A. F. (2025). Semantic classification of Indonesian consumer health questions. *Journal of Biomedical Semantics, 16*, Article 13. https://jbiomedsem.biomedcentral.com/articles/10.1186/s13326-025-00334-5

Labrak, Y., Bazoge, A., Morin, E., Gourraud, P.-A., Rouvier, M., & Dufour, R. (2024). BioMistral: A collection of open-source pretrained large language models for medical domains. *Findings of the Association for Computational Linguistics: ACL 2024*, 5848–5864. https://arxiv.org/abs/2402.10373

Paiola, P. H., Garcia, G. L., Manesco, J. R. R., Roder, M., Rodrigues, D., & Papa, J. P. (2025). Adapting LLMs for the medical domain in Portuguese: A study on fine-tuning and model evaluation. *Proceedings of WSCG 2025*. https://doi.org/10.24132/CSRN.2025-37

Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out* (pp. 74–81). Association for Computational Linguistics. https://aclanthology.org/W04-1013/

Firdaus, D., Sumardi, I., & Kulsum, Y. (2024). Integrating Retrieval-Augmented Generation with LLM Mistral 7b for Indonesian Medical Herb. *Jurnal Informatika Sunan Kalijaga (JISKA), 9*(3), 230–243. https://ejournal.uin-suka.ac.id/saintek/JISKA/article/view/4485

Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). Benchmarking retrieval-augmented generation for medicine. *Findings of the Association for Computational Linguistics: ACL 2024*, 6233–6251. https://arxiv.org/abs/2402.13178

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems, 30*, 5998–6008. https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems, 36*. https://arxiv.org/abs/2305.14314

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv preprint arXiv:2106.09685. https://arxiv.org/abs/2106.09685

Qwen Team. (2025). *Qwen2.5 Technical Report*. arXiv preprint arXiv:2412.15115. https://arxiv.org/abs/2412.15115

AI Singapore. (2024). *SEA-LION: Southeast Asian Languages in One Network* [Technical report]. AI Singapore. https://sea-lion.ai

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). *Retrieval-Augmented Generation for Large Language Models: A survey*. arXiv preprint arXiv:2312.10997. https://arxiv.org/abs/2312.10997

Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval, 3*(4), 333–389. https://doi.org/10.1561/1500000019

Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *Findings of the Association for Computational Linguistics: ACL 2024*, 2318–2335. https://arxiv.org/abs/2402.03216

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report*. arXiv preprint arXiv:2402.05672. https://arxiv.org/abs/2402.05672

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474. https://arxiv.org/abs/2005.11401

Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318. https://aclanthology.org/P02-1040/

Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). *BERTScore: Evaluating text generation with BERT*. International Conference on Learning Representations (ICLR) 2020. https://arxiv.org/abs/1904.09675

LAMPIRAN